



Primo giorno: pomeriggio

Agenda 2/8

— Le fondamentali

La programmazione funzionale

Un paradigma utile per il calcolo parallelo

Strutture dati

RDDs, DataSets e DataFrames

Operazioni sui dati


Transformazioni e Azioni; Valutazioni «pigre»; persistenza (cache)

Punti di riferimento

Documentazione; Cloudera, Hortonworks; Databricks;
sorgente su github

Esercizi di laboratorio

Mappe, filtri e qualche azione

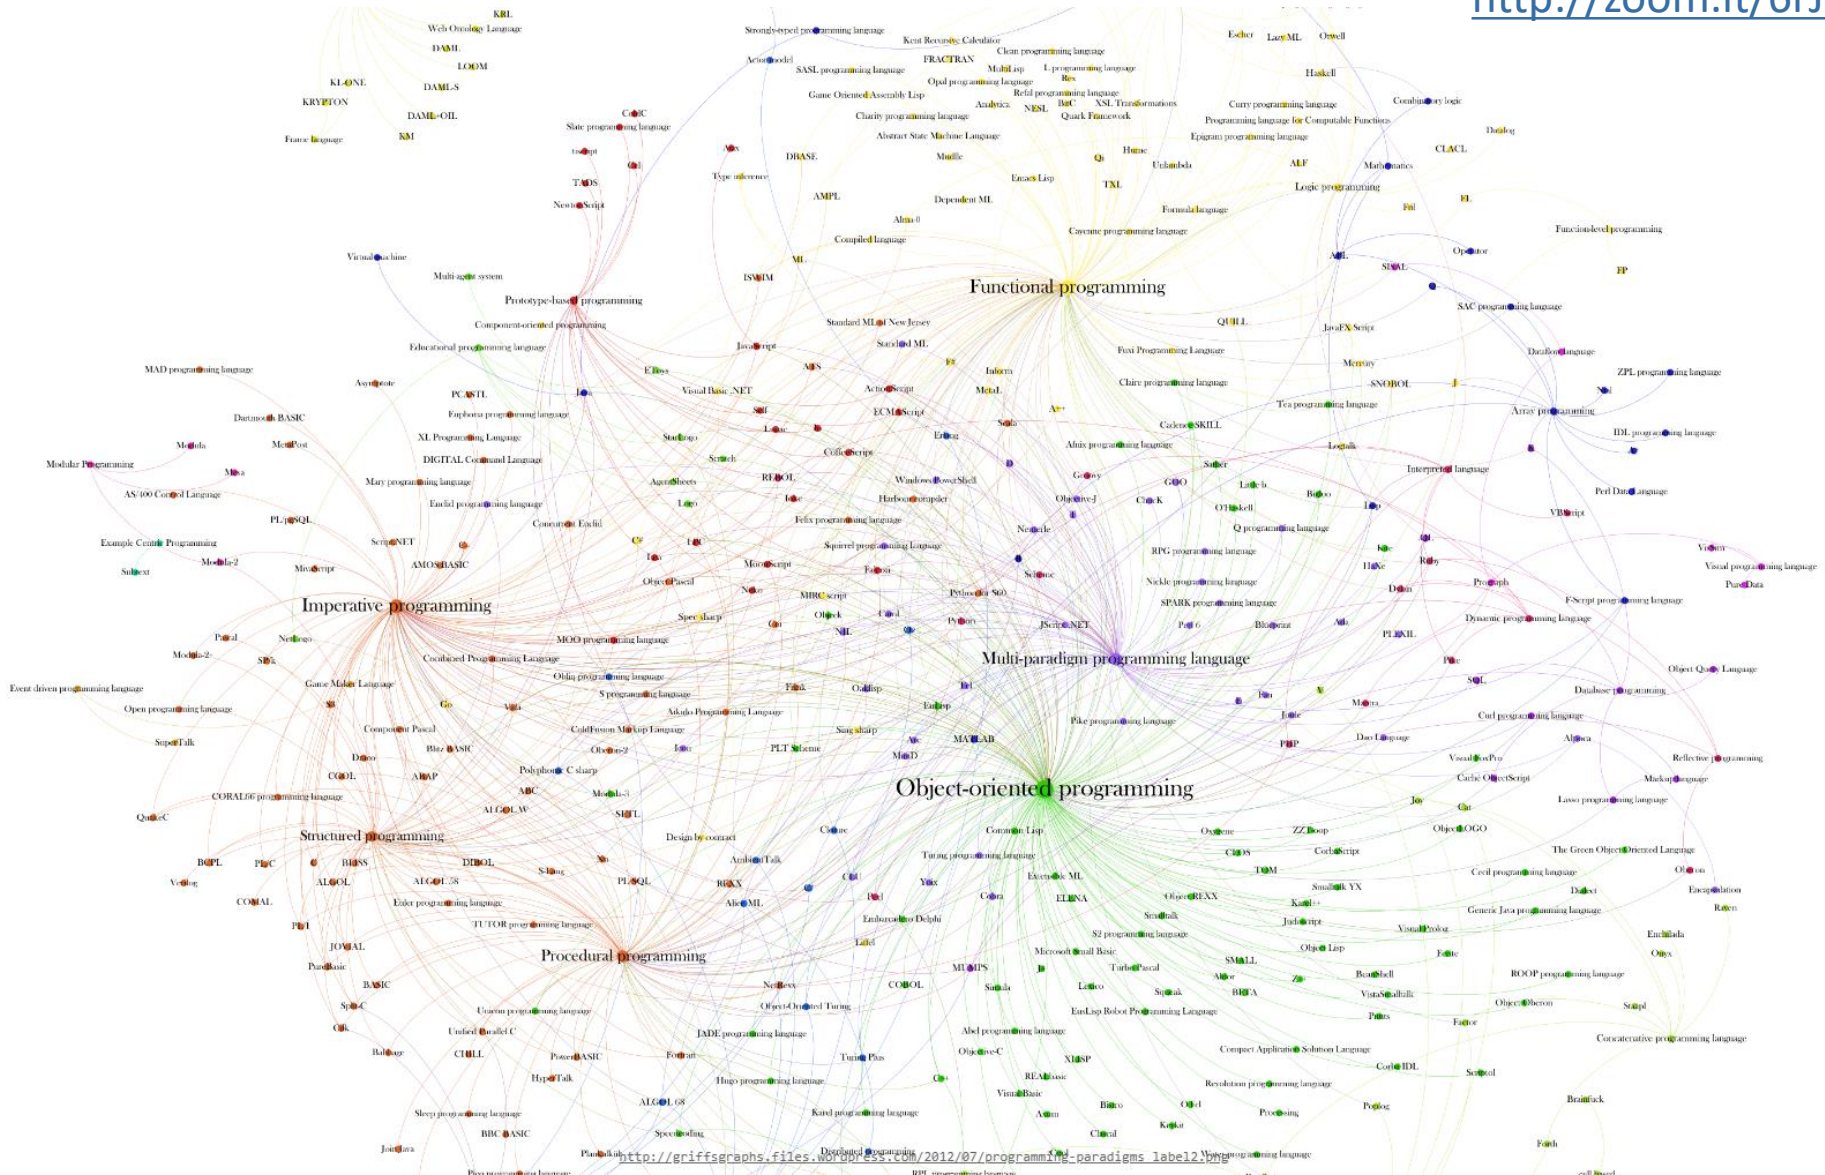


Cos'è la Programmazione Funzionale?

Esistono più di 8000 linguaggi di programmazione

The Graph of Programming Paradigms


<http://zoom.it/6rJp>



<https://www.tiobe.com/tiobe-index/>

TIOBE Programming Community Index

Source: www.tiobe.com



«A language that doesn't affect the way your think about programming is not worth knowing».

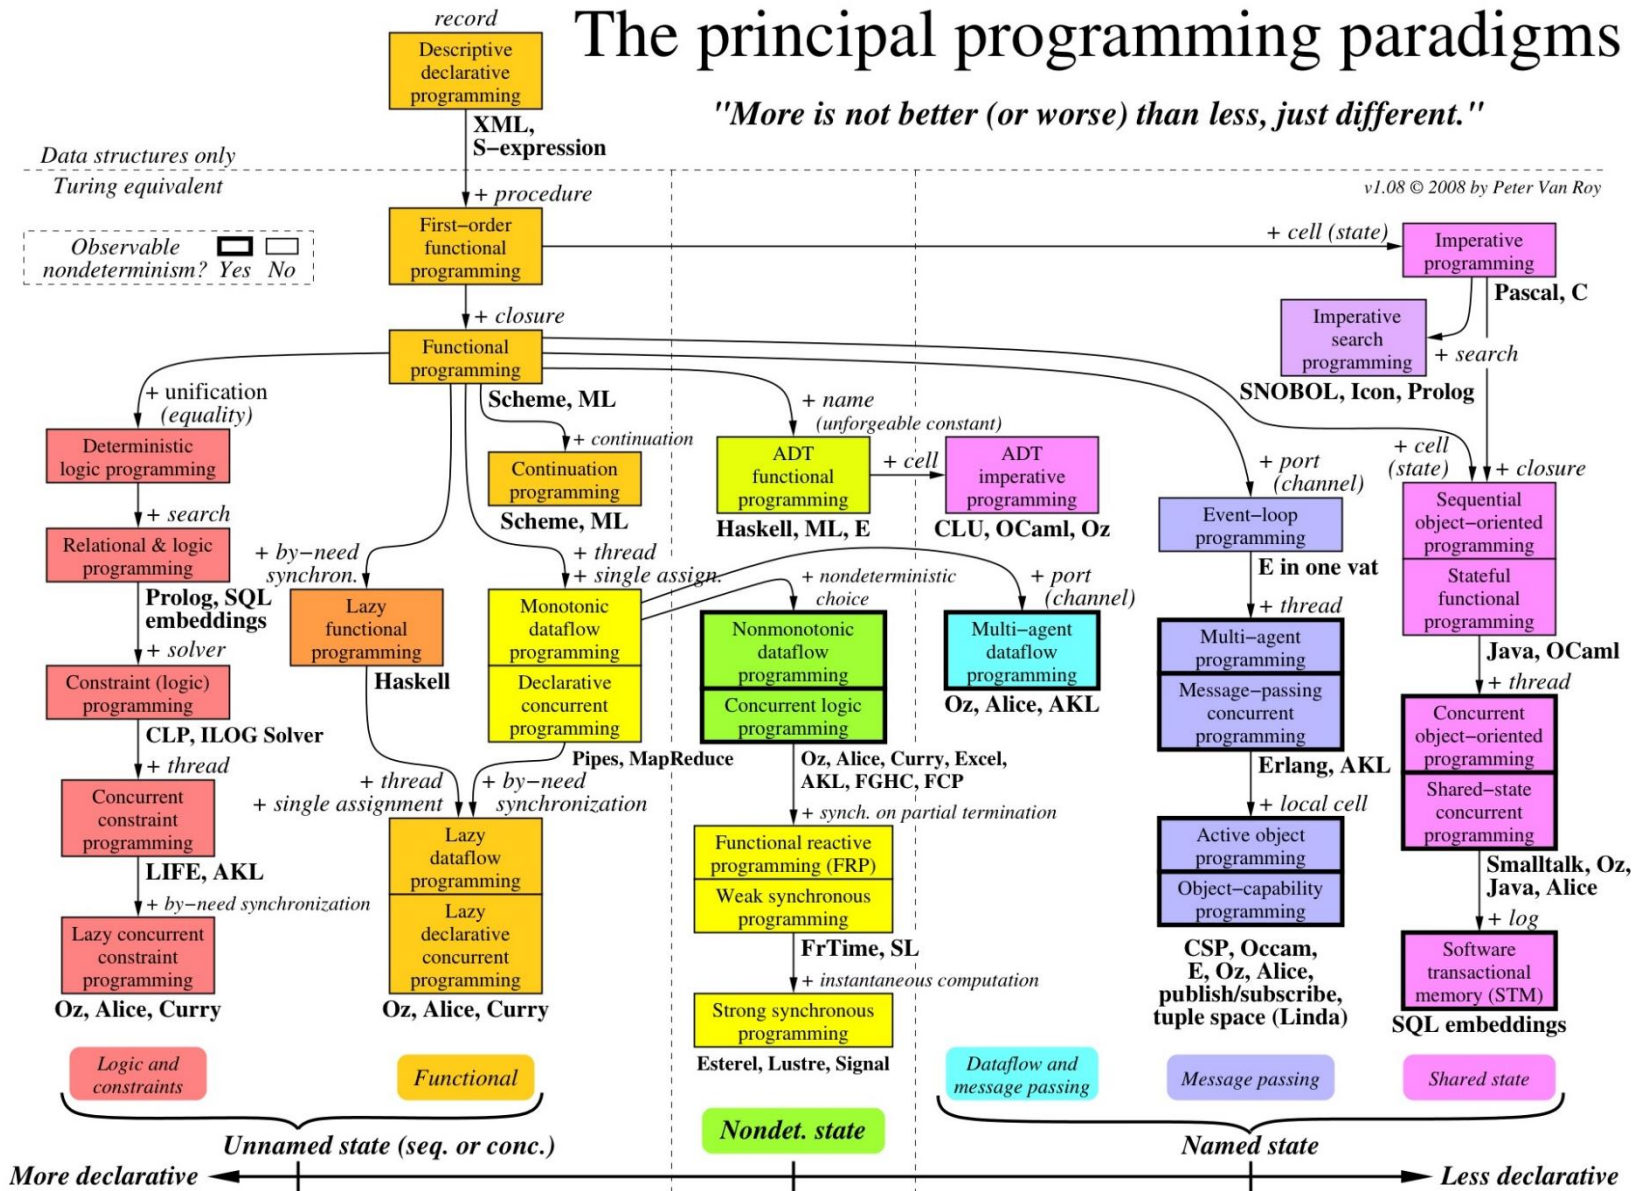
— Alan Perlis



The principal programming paradigms

"More is not better (or worse) than less, just different."

v1.08 © 2008 by Peter Van Roy



Paradigmi di programmazione : *procedurale vs. funzionale*

Programmazione procedurale o imperativa

Un programma è una serie di istruzioni che possono modificare la memoria.

Programmazione funzionale

Il programma è una funzione che calcola un output a partire da un certo numero di input.

Paradigmi di programmazione : *procedurale vs. funzionale*

Programmazione procedurale o imperativa

```
val arr = Seq(1, 2, 3, 5, 8, 13, 21)
var sum = 0
for ( x <- arr ) sum += x
```

Programmazione funzionale

```
val arr = Seq(1, 2, 3, 5, 8, 13, 21)
val sum = arr.reduce((a,b) => a+b)
```

Caratteristiche del paradigma funzionale

- Niente effetti collaterali (*side effects*)
- Non importa l'ordine di esecuzione
- Le funzioni vengono passate come argomento

*Ideas from Functional Programming
that improve software design:*



**AVOID HIDDEN
SIDE-EFFECTS**



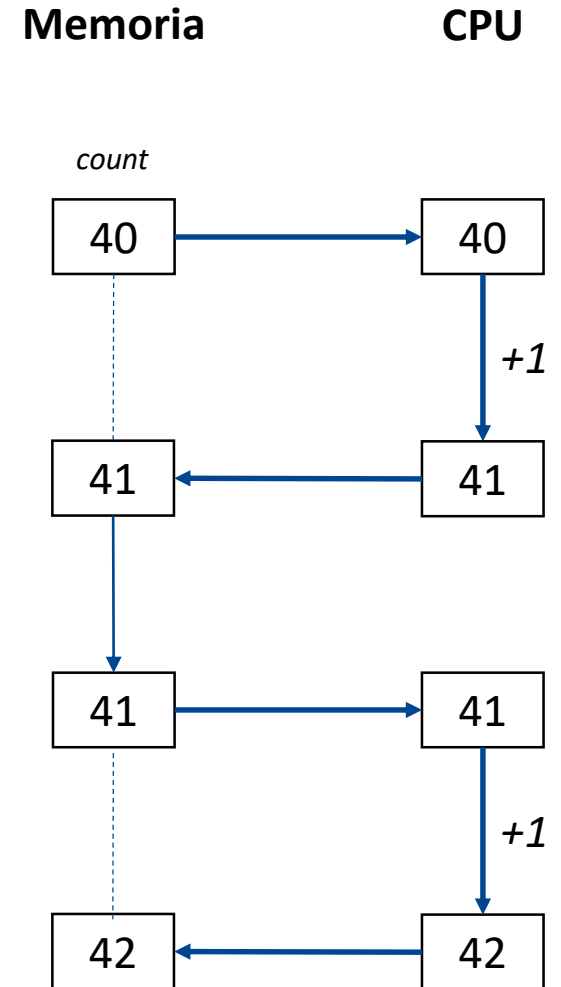
**ENSURE REFERENTIAL
TRANSPARENCY**



**USE LIST-PROCESSING
FUNCTIONS**

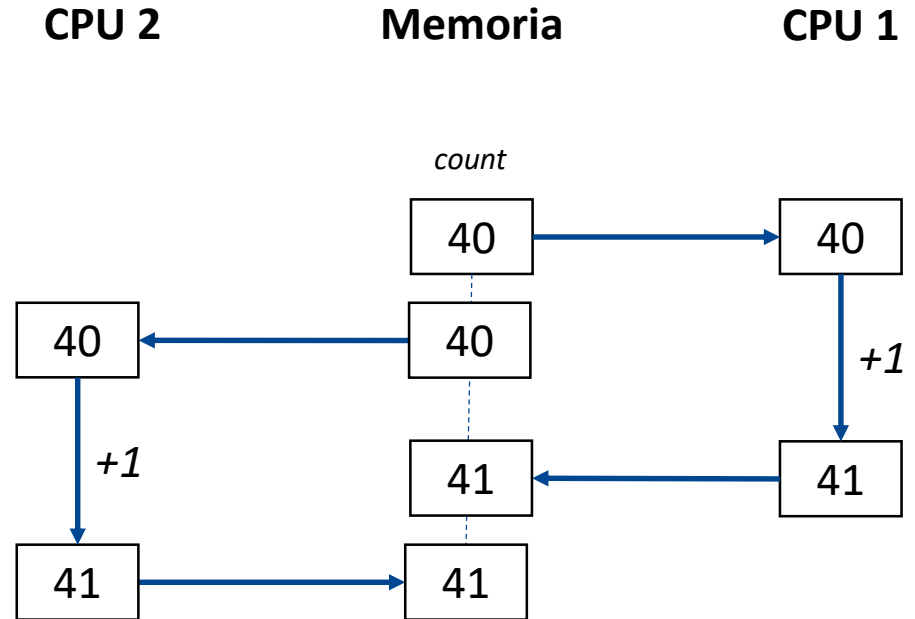
Gli effetti collaterali

```
for( item <- items ) {  
  ...  
  if ( condizione ) {  
    count = count + 1  
  }  
}
```



Gli effetti collaterali

```
for( item <- items ) {  
  ...  
  if ( condizione ) {  
    count = count + 1  
  }  
}
```



ERRORE!

Gli effetti collaterali

Se sono ammessi effetti collaterali una funzione invocata due volte può ritornare valori diversi


```
var i = 0  
def pippo() : Int = { i+=1; return i }
```

Conclusione dell'intermezzo

Il paradigma funzionale è utile nei sistemi di calcolo distribuito

Strutture dati immutabili

Assenza di effetti collaterali




E' più facile:


- Distribuire i dati fra i nodi
- Ricalcolare un dato intermedio in caso di fallimento di un nodo
- Ottimizzare il flusso dei calcoli

Torniamo a Spark!

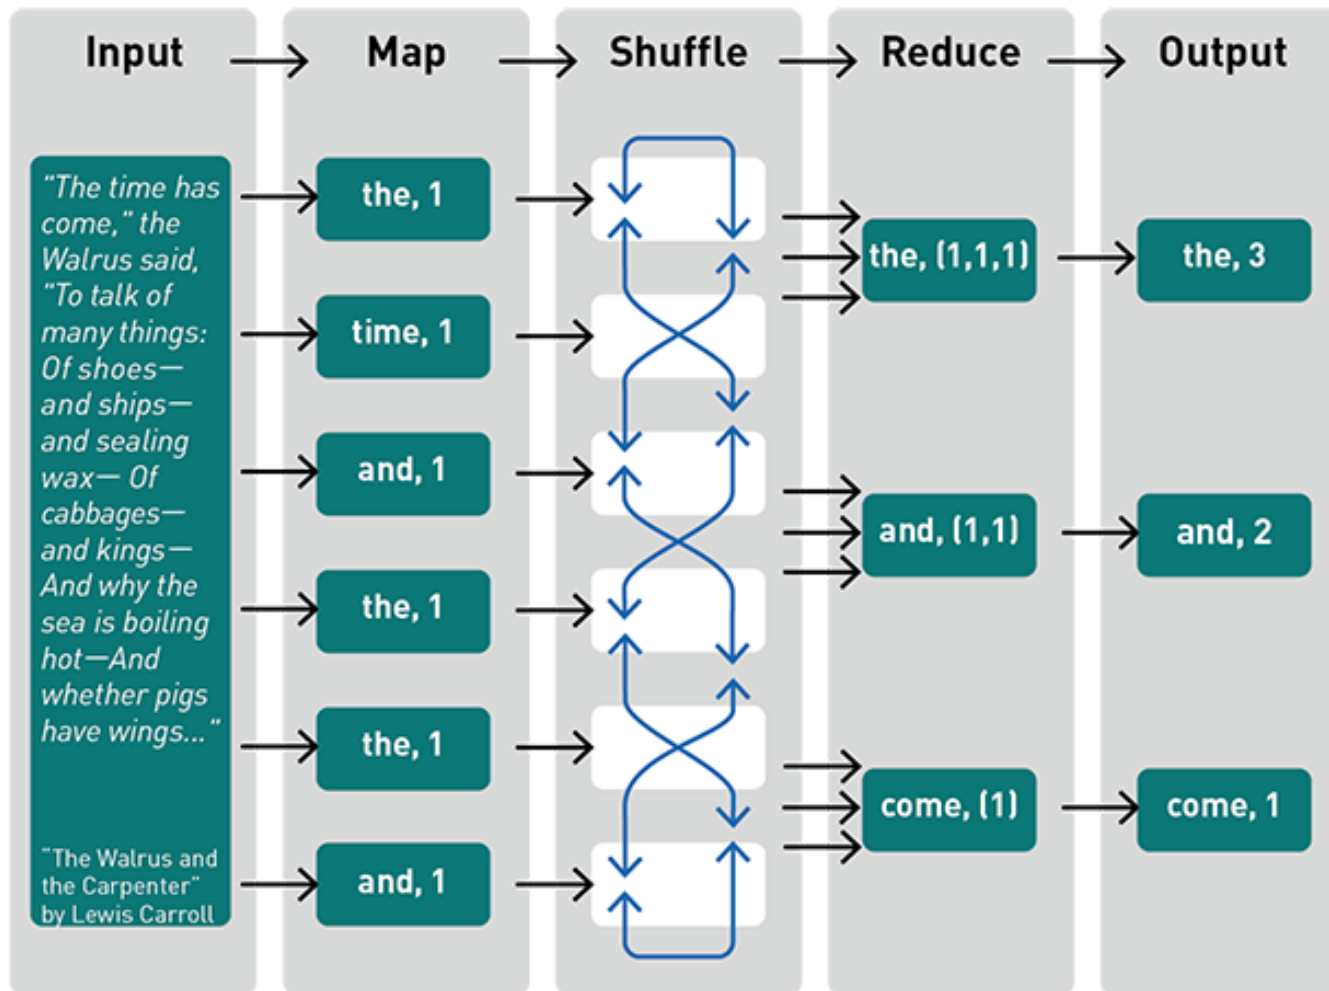
Spark è una diretta evoluzione di Hadoop Map Reduce




MapReduce



MapReduce




Un esempio di calcolo più complesso: PageRank



$$\text{PageRank of site} = \sum \frac{\text{PageRank of inbound link}}{\text{Number of links on that page}}$$


OR

$$PR(u) = (1 - d) + d \times \sum \frac{PR(v)}{N(v)}$$



Algoritmo iterativo

MapReduce



Se l'algoritmo prevede diverse fasi di MapReduce i dati intermedi devono essere scritti su disco ogni volta

Spark vs MapReduce

Spark è una diretta evoluzione di Hadoop Map Reduce


Mantiene il concetto base: **Flusso di dati attraverso un grafo di operazioni**

Le principali differenze sono:


- I dati intermedi sono conservati in memoria
- Il grafo delle operazioni (**DAG**= *Direct Acyclic Graph*) può essere più complicato



I dati intermedi sono conservati in memoria





Il grafo delle operazioni (**DAG**= *Direct Acyclic Graph*) può essere più complicato



Come definisco il DAG?

Le strutture dati in Apache Spark

Le strutture dati condizionano il modo in cui creiamo i programmi



Le strutture dati in Apache Spark

API Strutturata (alto livello)

DataFrames & DataSet

API Non strutturata (basso livello)

RDD (*Resilient Distributed Datasets*)

Le strutture dati in Apache Spark

Un'analisi storica

- Le prime versioni di Spark sono fondate sugli **RDD** (almeno da *Spark0.6, 2012*)
RDD = « an immutable, partitioned collection of elements that can be operated on in parallel »
- In un secondo tempo vengono inseriti i **DataFrame** (*Spark1.3, 2015*)
DataFrame = « is equivalent to a relational table in Spark SQL » (*experimental*)
- I **Dataset** sono un'estensione dei *DataFrame* (*Spark1.6, gennaio 2016*)
Dataset = « a strongly typed collection of objects that can be transformed in parallel using functional or relational operations » (*experimental*)
- A partire da *Spark2.0 (luglio 2016)* i *DataFrame* e i *Dataset* sono unificati
« A *Dataset* is a strongly typed collection of domain-specific objects that can be transformed in parallel using functional or relational operations. Each *Dataset* also has an untyped view called a *DataFrame*, which is a *Dataset of Row* »

Caratteristiche comuni di *RDD*, *DataFrame* e *Dataset*

- Sono collezioni di dati *distribuite* e *immutabili*.
- Supportano *trasformazioni* e *azioni* che vengono eseguite in parallelo (le trasformazioni sono eseguite in maniera «pigra»).
- Sono i vertici del **DAG** (*Direct Acyclic Graph*) che rappresenta il calcolo da eseguire (le trasformazioni sono gli archi)

DataFrame e *DataSet* sono implementati mediante *RDD*.

È possibile passare facilmente da una rappresentazione all'altra.

```
scala> val a = spark.range(1,1000000)
a: org.apache.spark.sql.Dataset[Long] = [id: bigint]

scala> val b = a.toDF()
b: org.apache.spark.sql.DataFrame = [id: bigint]

scala> b.rdd.partitions.length
res7: Int = 2
```


Differenze principali fra *RDD*, *DataFrame* e *Dataset*

Livello

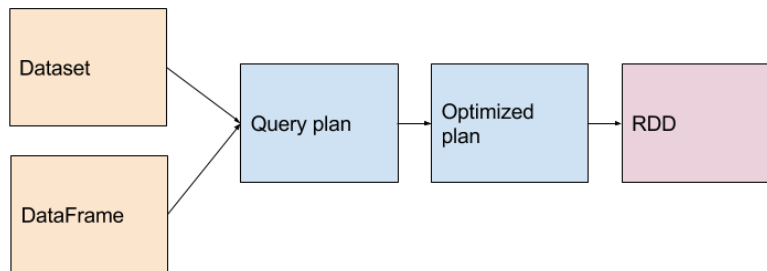
RDD sono considerate un'API a basso livello: permettono maggiore controllo, ma sono meno ottimizzabili da Spark. Inoltre sono un po' più complicate da usare.

Schema

DataFrame e **Dataset** hanno una definizione formale dei dati. **RDD** no.

Prestazioni

DataFrame e **Dataset** sono ottimizzate (*Catalyst* e *Tungsten*)



Differenze principali fra *RDD*, *DataFrame* e *Dataset*

Sicurezza rispetto ai tipi

RDD e *Dataset* hanno un tipo ben definito in fase di compilazione.

Gli errori legati al tipo con i *DataFrame* possono essere individuati solo durante l'esecuzione.

Linguaggi

RDD e *DataFrame* sono disponibili per tutti i linguaggi

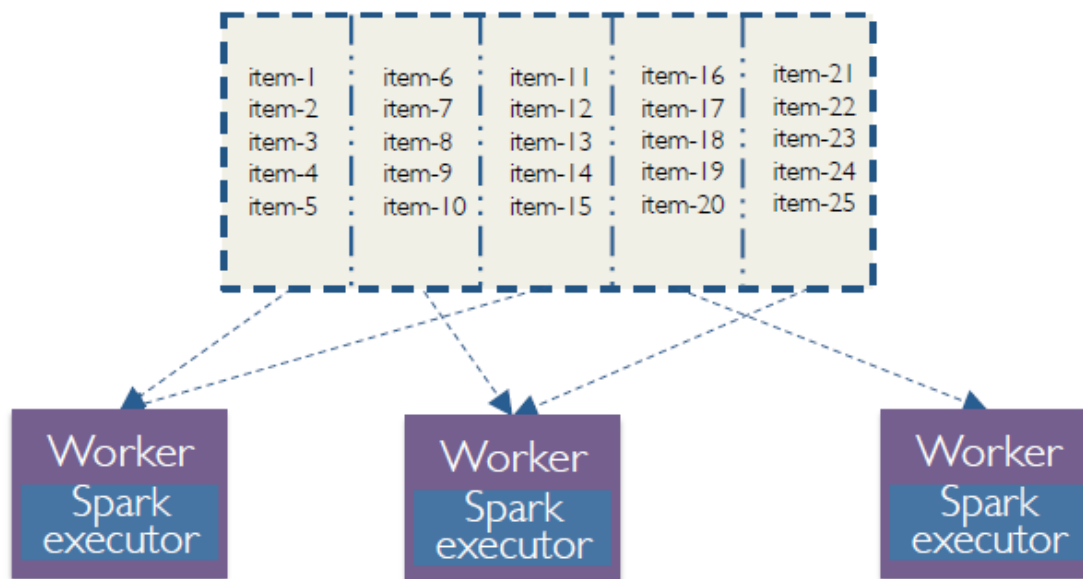
I *DataSet* solo in Java e Scala

Le partizioni

Gli RDD (e quindi i DataFrame e Dataset) sono dati distribuiti sui nodi del cluster

```
val rdd = sc.textFile("hdfs://localhost:9000/path/to/my/file")  
val errorCount = rdd.filter(_.startsWith("ERROR")).count()
```

RDD split into 5 partitions



Le partizioni

Gli RDD (e quindi i DataFrame e Dataset) sono dati distribuiti sui nodi del cluster

Leggo un file su HDFS, già diviso in partizioni

```
val rdd = sc.textFile("data/log.txt")
```

```
rdd: org.apache.spark.rdd.RDD[String] = data/log.txt MapPartitionsRDD[9] at textFile at <console>:67  
Took: 2.912s, at 2019-03-03 13:59
```

```
println(rdd.getNumPartitions)
```

```
2
```

```
Took: 1.464s, at 2019-03-03 14:02
```

Creo un RDD a partire da una sequenza numerica. Decido esplicitamente le partizioni

```
val numeri = sc.parallelize(1 to 1000000, 7)
```

```
numeri: org.apache.spark.rdd.RDD[Int] = ParallelCollectionRDD[18] at parallelize at <console>:67  
Took: 1.374s, at 2019-03-03 14:06
```

```
println(numeri.getNumPartitions)
```


```
7
```

```
Took: 1.281s, at 2019-03-03 14:06
```

Immutabilità

Non posso modificare il contenuto. Devo creare una nuova entità modificata

```
val tempC = tempF.map(t => (t-32)*5/9)
```



Riassumendo

Le strutture dati in Spark:

- *DataFrame*, *Dataset* e *RDD*
- Immutabili e distribuite sui nodi del cluster
- Vengono manipolate con *trasformazioni* e *azioni*

Le Trasformazioni sono «pigre»

Il calcoli effettivi vengono determinati dalle **Azioni**

```
val rdd = sc.textFile("data/log.txt")
rdd: org.apache.spark.rdd.RDD[String] = data/log.txt MapPartitionsRDD[34] at textFile at <console>:6
7
Took: 0.899s, at 2019-03-03 14:59

val rdd2 = rdd.filter(s=>s.contains("ERROR"))
rdd2: org.apache.spark.rdd.RDD[String] = MapPartitionsRDD[35] at filter at <console>:69
Took: 0.827s, at 2019-03-03 14:59

val rdd3 = rdd2.filter(s=>s.contains("worker process"))
rdd3: org.apache.spark.rdd.RDD[String] = MapPartitionsRDD[36] at filter at <console>:71
Took: 0.939s, at 2019-03-03 14:59

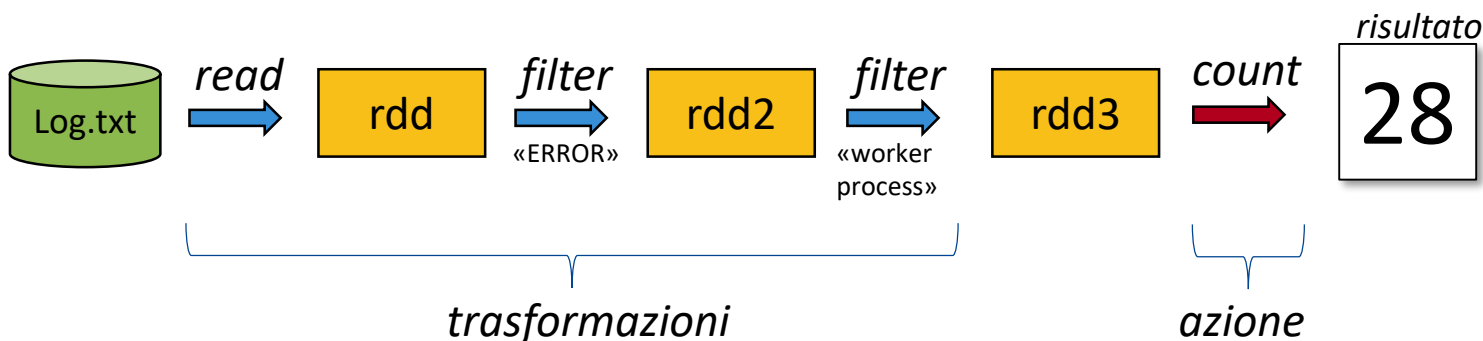
rdd3.count()
res55: Long = 28
28
Took: 1.275s, at 2019-03-03 14:59
```

Non succede nulla

Non succede nulla

Non succede nulla


Parte il calcolo



Cache

Un'ottimizzazione importante

L'esecuzione di un'**azione** determina il calcolo di tutte le **trasformazioni** da cui l'azione dipende.



È possibile salvare il risultato in modo da evitare il ricalcolo.

I comandi relativi sono *cache()* e *persist()*

I dati possono essere salvati in memoria, su disco o nella memoria *off-heap*

Cache

Un'ottimizzazione importante

```
val df = spark.read
  .option("header", true)
  .option("inferSchema", true)
  .option("mode", "FAILFAST")
  .csv("data/earthquake.csv")
  .cache()
```


df: org.apache.spark.sql.Dataset[org.apache.spark.sql.Row] = [id: decimal(3,-11), date: string ... 15 more fields]

Took: 1.069s, at 2019-03-03 18:40

Lineage


RDD (e quindi anche DataFrame e Dataset) sono «resilienti», cioè tolleranti agli errori.

Se una partizione di un RDD si perde (ad es. per il fallimento di un nodo) Spark deve essere in grado di ricostruirla.



Ogni RDD sa come ricostruire il suo contenuto in base agli RDD da cui dipende.

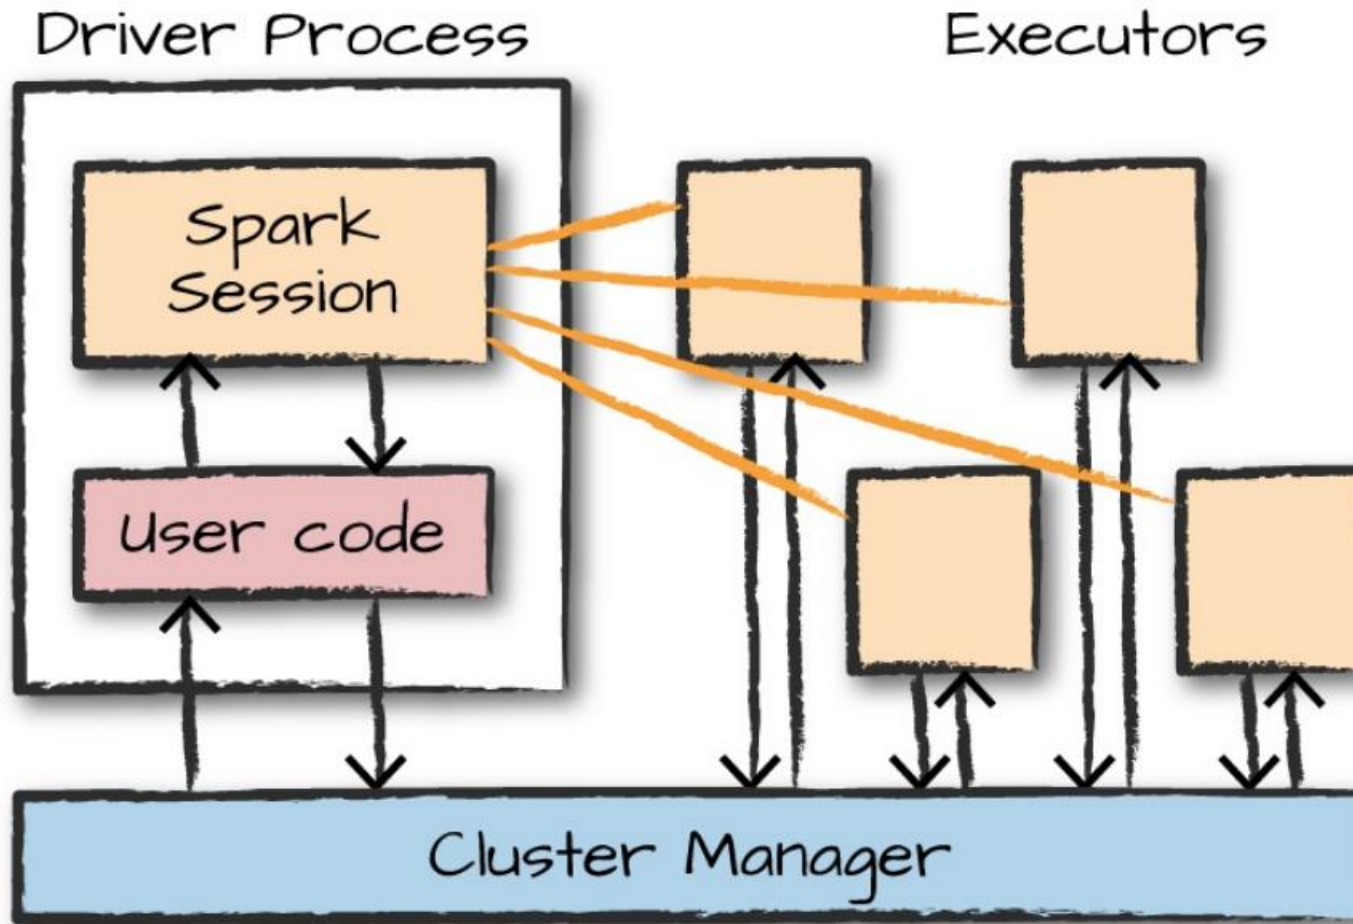
Questa informazione si chiama «lineage»



L'applicazione Spark

Struttura di un'applicazione Spark

Un'applicazione Spark prevede un processo **Driver** ed un certo numero di **Esecutori**.



La Sessione

SparkSession è l'oggetto che permette di dare comandi all'applicazione Spark.

Quando si usa Spark in modalità interattiva (con il comando *spark-shell* o con un *Notebook*).

⇒ Viene automaticamente creato un oggetto (costante) *SparkSession* di nome ***spark***.

Quando si lancia un'applicazione precompilata con *spark-submit*

⇒ L'oggetto *SparkSession* deve essere creato esplicitamente

La Sessione

Il codice più antico (cioè di pochi anni fa!!) usa un altro oggetto: lo *SparkContext*.

Questo oggetto viene ancora utilizzato dall'API relativa agli RDD (ad es. per creare un RDD).

Nelle sessioni interattive (spark-shell) la costante **sc** contiene lo *SparkContext*

```
val rdd = sc.parallelize(1 to 1000, 5)
```

Lo spark context è sempre contenuto nella SparkSession:

```
val rdd = spark.sparkContext.parallelize(1 to 1000, 5)
```


La Sessione

Per creare (o recuperare) l'istanza della *SparkSession* nei programmi si può fare:

```
val spark = SparkSession.builder().getOrCreate()
```

Ed è possibile passare dei parametri di configurazione:

```
val spark = SparkSession  
  .builder()  
  .appName("SparkSessionZipsExample")  
  .config("spark.sql.warehouse.dir", warehouseLocation)  
  .enableHiveSupport()  
  .getOrCreate()
```

Qualche comando per il laboratorio di oggi

Qualche «ricetta» Spark

Per il laboratorio di oggi pomeriggio

Sommare i cubi del primo milione di interi

```
val numbers = spark.range(1,1000001)
numbers.map(x=>BigDecimal(x)).map(x=>x*x*x).reduce(_+_)
```

Leggere un file CSV

```
val earthquakes = spark.read
    .option("header",true)
    .option("inferSchema",true)
    .option("mode","failfast")
    .csv("data/earthquake.csv")
earthquakes.printSchema()
```

Qualche «ricetta» Spark

Per il laboratorio di oggi

```
val earthquake = spark.read
  .option("header", true)
  .option("inferSchema", true)
  .option("mode", "FAILFAST")
  .csv("data/earthquake.csv")
earthquake.printSchema()
```

```
root
|-- id: decimal(3,-11) (nullable = true)
|-- date: string (nullable = true)
|-- time: string (nullable = true)
|-- lat: double (nullable = true)
|-- long: double (nullable = true)
|-- country: string (nullable = true)
|-- city: string (nullable = true)
|-- area: string (nullable = true)
|-- direction: string (nullable = true)
|-- dist: double (nullable = true)
|-- depth: double (nullable = true)
|-- xm: double (nullable = true)
|-- md: double (nullable = true)
|-- richter: double (nullable = true)
|-- mw: double (nullable = true)
|-- ms: double (nullable = true)
|-- mb: double (nullable = true)
```

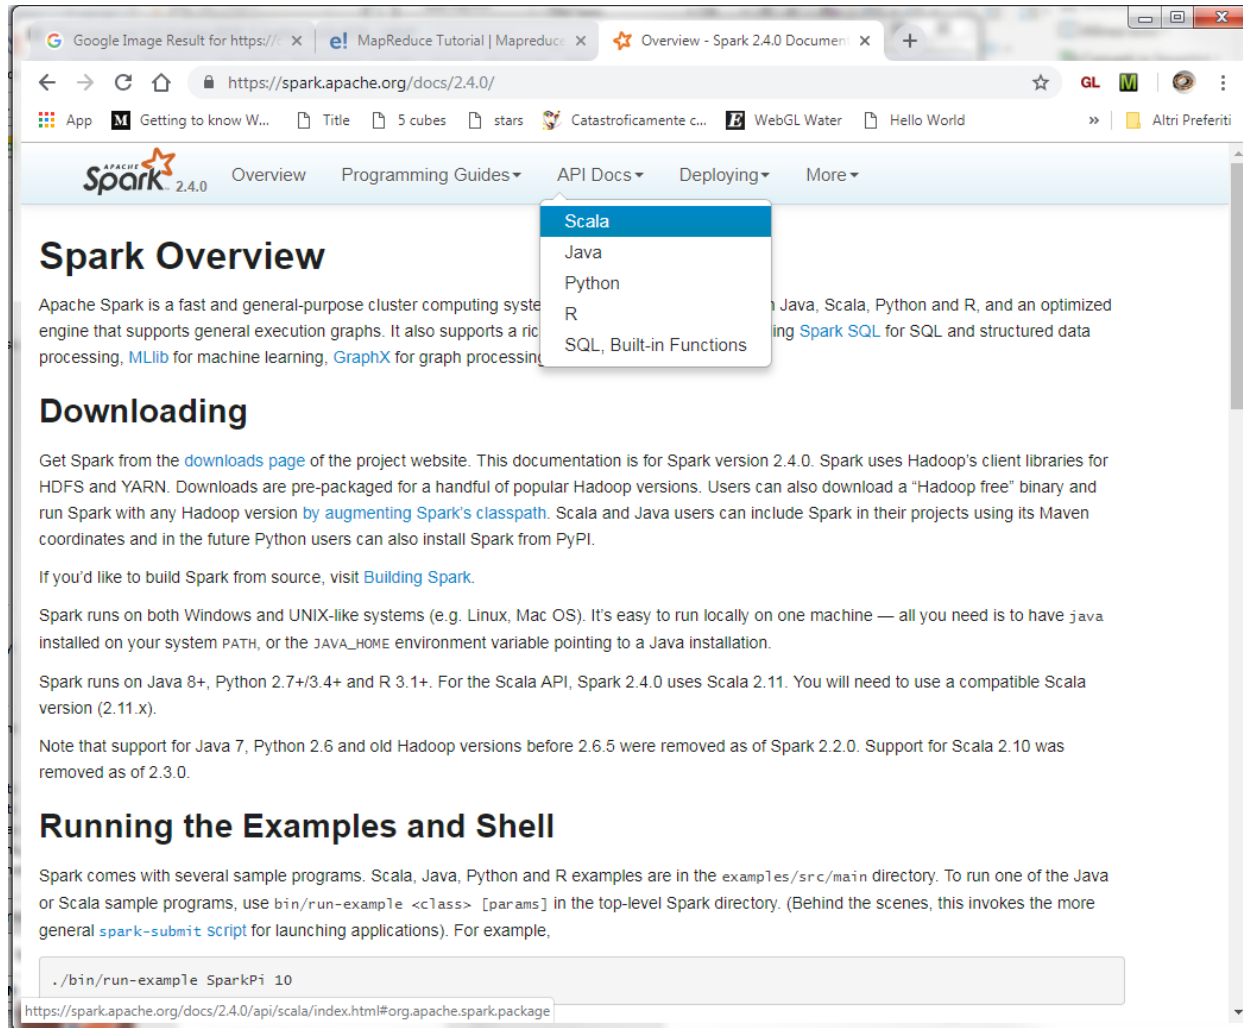
```
earthquake: org.apache.spark.sql.DataFrame = [id: decimal(3,-11), date: string ... 15 more fields]
```

Took: 1.732s, at 2019-02-28 20:02

La documentazione

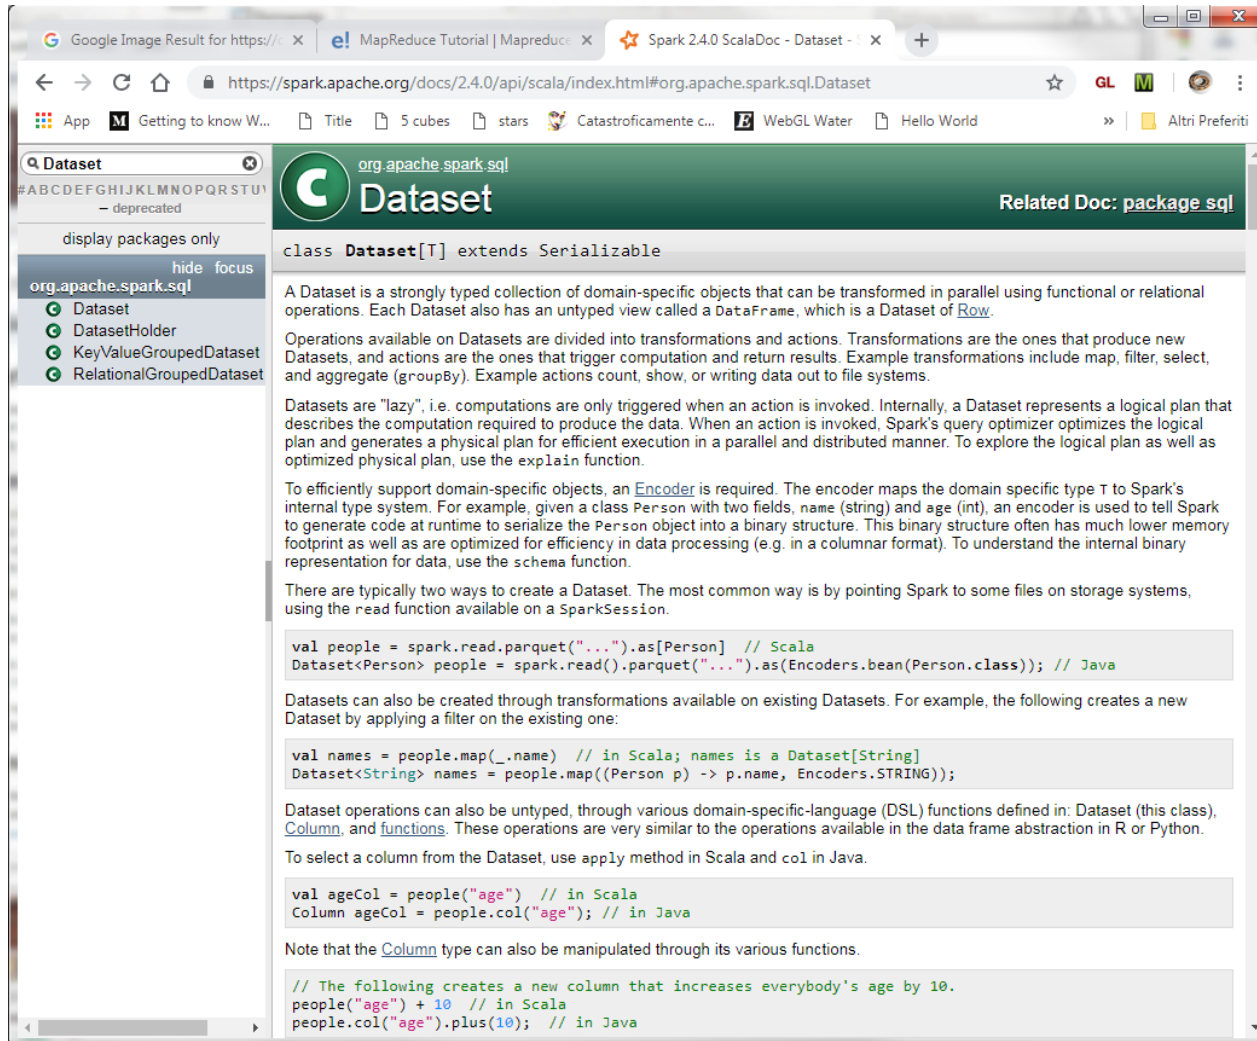
La documentazione

<https://spark.apache.org/docs/2.4.0/>



La documentazione

<https://spark.apache.org/docs/2.4.0/>



The screenshot shows a web browser displaying the Spark 2.4.0 ScalaDoc for the `org.apache.spark.sql.Dataset` class. The browser tabs include "Google Image Result for https://...", "MapReduce Tutorial | Mapreduce...", and "Spark 2.4.0 ScalaDoc - Dataset". The address bar shows the URL `https://spark.apache.org/docs/2.4.0/api/scala/index.html#org.apache.spark.sql.Dataset`. The page features a sidebar on the left with a search bar containing "Dataset" and a list of packages under "org.apache.spark.sql", including "Dataset", "DatasetHolder", "KeyValueGroupedDataset", and "RelationalGroupedDataset". The main content area has a green header with the "org.apache.spark.sql" logo and the word "Dataset". Below the header, it shows the class signature `class Dataset[T] extends Serializable`. The text explains that a Dataset is a strongly typed collection of domain-specific objects that can be transformed in parallel using functional or relational operations. It also mentions that each Dataset has an untyped view called a `DataFrame`, which is a `Dataset of Row`. Operations available on Datasets are divided into transformations and actions. Transformations are the ones that produce new Datasets, and actions are the ones that trigger computation and return results. Example transformations include `map`, `filter`, `select`, and `aggregate (groupBy)`. Example actions include `count`, `show`, or writing data out to file systems. Datasets are "lazy", i.e. computations are only triggered when an action is invoked. Internally, a Dataset represents a logical plan that describes the computation required to produce the data. When an action is invoked, Spark's query optimizer optimizes the logical plan and generates a physical plan for efficient execution in a parallel and distributed manner. To explore the logical plan as well as optimized physical plan, use the `explain` function. To efficiently support domain-specific objects, an `Encoder` is required. The encoder maps the domain specific type `T` to Spark's internal type system. For example, given a class `Person` with two fields, `name (string)` and `age (int)`, an encoder is used to tell Spark to generate code at runtime to serialize the `Person` object into a binary structure. This binary structure often has much lower memory footprint as well as are optimized for efficiency in data processing (e.g. in a columnar format). To understand the internal binary representation for data, use the `schema` function. There are typically two ways to create a Dataset. The most common way is by pointing Spark to some files on storage systems, using the `read` function available on a `SparkSession`. The following code snippets show how to create a Dataset from a Parquet file using Scala and Java, how to create a Dataset from an existing Dataset by applying a filter, and how to create a Dataset from a Column. The code snippets are as follows:

```
val people = spark.read.parquet("...").as[Person] // Scala
Dataset<Person> people = spark.read().parquet("...").as(Encoders.bean(Person.class)); // Java
```

Datasets can also be created through transformations available on existing Datasets. For example, the following creates a new Dataset by applying a filter on the existing one:

```
val names = people.map(_.name) // in Scala; names is a Dataset[String]
Dataset<String> names = people.map((Person p) -> p.name, Encoders.STRING);
```

Dataset operations can also be untyped, through various domain-specific-language (DSL) functions defined in: `Dataset` (this class), `Column`, and `functions`. These operations are very similar to the operations available in the data frame abstraction in R or Python. To select a column from the Dataset, use `apply` method in Scala and `col` in Java.



```
val ageCol = people("age") // in Scala
Column ageCol = people.col("age"); // in Java
```

Note that the `Column` type can also be manipulated through its various functions.

```
// The following creates a new column that increases everybody's age by 10.
people("age") + 10 // in Scala
people.col("age").plus(10); // in Java
```

Un po' di coordinate

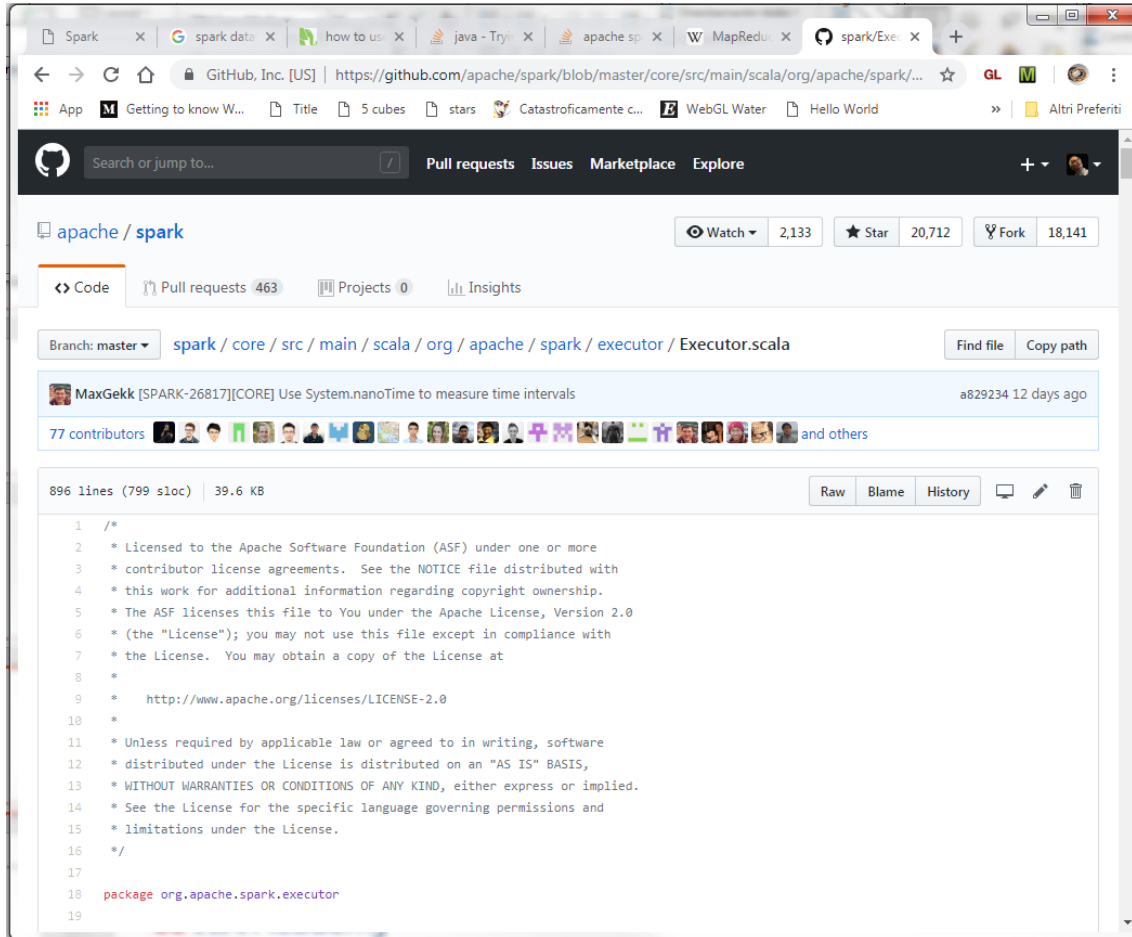
cloudera



databricks®

Apache Spark è OpenSource

[https://github.com/apache/spark/blob/master/core/src/...](https://github.com/apache/spark/blob/master/core/src/main/scala/org/apache/spark/...)



The screenshot shows the GitHub web interface for the Apache Spark repository. The browser's address bar displays the URL: `https://github.com/apache/spark/blob/master/core/src/main/scala/org/apache/spark/...`. The repository page for 'apache / spark' is visible, showing 2,133 watchers, 20,712 stars, and 18,141 forks. The 'Code' tab is selected, and the file path 'spark / core / src / main / scala / org / apache / spark / executor / Executor.scala' is shown. The commit history for this file is displayed, with the most recent commit by MaxGekk [SPARK-26817][CORE] titled 'Use System.nanoTime to measure time intervals' from 12 days ago. Below the commit information, the file content is shown, starting with a multi-line Apache License header. The file statistics indicate it contains 896 lines (799 sloc) and is 39.6 KB in size. Navigation buttons for 'Raw', 'Blame', and 'History' are visible above the code content.

```
1  /*
2   * Licensed to the Apache Software Foundation (ASF) under one or more
3   * contributor license agreements.  See the NOTICE file distributed with
4   * this work for additional information regarding copyright ownership.
5   * The ASF licenses this file to You under the Apache License, Version 2.0
6   * (the "License"); you may not use this file except in compliance with
7   * the License.  You may obtain a copy of the License at
8   *
9   * http://www.apache.org/licenses/LICENSE-2.0
10  *
11  * Unless required by applicable law or agreed to in writing, software
12  * distributed under the License is distributed on an "AS IS" BASIS,
13  * WITHOUT WARRANTIES OR CONDITIONS OF ANY KIND, either express or implied.
14  * See the License for the specific language governing permissions and
15  * limitations under the License.
16  */
17
18  package org.apache.spark.executor
19
```

