Secondo giorno: pomeriggio

Agenda 4/8

Aggregazioni

$$\left(\sum_{i=1}^{n} p_i x_i^2\right) - \mu^2$$

Tipi di aggregrazione
Intero DataFrame, *group by*, *window*, *grouping set, rollup, cube*

Statistiche
Conteggi, somme, media, varianza, ecc.

Aggregazione su tipi complessi
Insiemi e liste

Window
Funzioni su finestre di dati: ranking, funzioni analitiche e di aggregazione

Funzioni di aggregazione definite dall'utente

Esercizi di laboratorio
Esercitazioni sugli argomenti trattati.

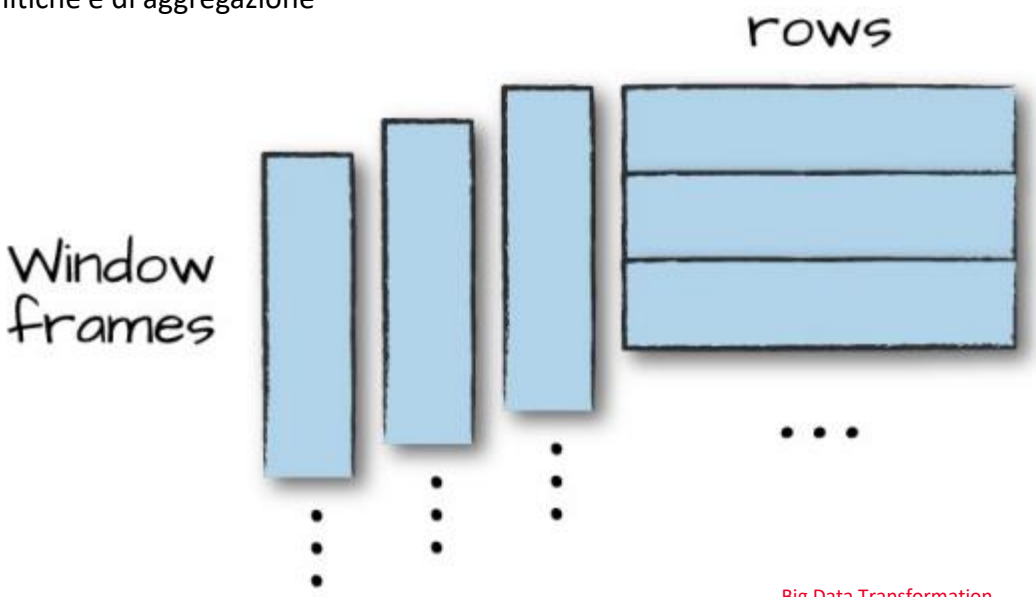

Aggregazioni

La pietra angolare dell'analisi di big data

Nelle aggregazioni bisogna specificare:

- Una ***chiave*** o un ***raggruppamento***
- Una ***funzione*** di aggregazione che agisce su una o più colonne.

La funzione di aggregazione genera un risultato per ogni Gruppo.

In genere la funzione è numerica (ma non sempre):

- somma,
- prodotto,
- un semplice conteggio,
- Ecc.

Aggregazioni

La pietra angolare dell'analisi di big data

Spark consente diversi tipi di raggruppamenti:

- L'intero *DataFrame* (ad es. per contare il numero di righe)
- *"group by"* : raggruppa in base al valore di una o più colonne
- "*window*" : calcola un valore a partire da un certo insieme di record collegati
- "*grouping set*" : calcola un aggregazione a più livelli:
  - "rollup" : permette di definire una gerarchia di aggregazioni
  - "cube" : calcola le aggregazioni con qualunque combinazione di colonne

Aggregazioni

La pietra angolare dell'analisi di big data

Dal punto di vista sintattico:

DataFrame => RelationalGroupedDataset => DataFrame (con aggregazione).

Es.:

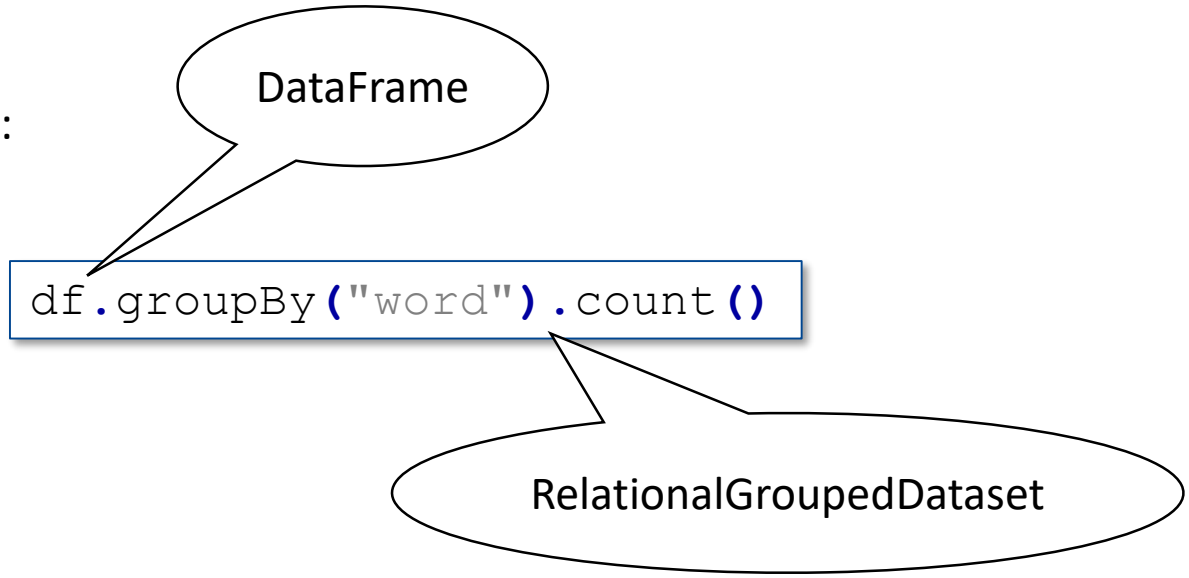

Aggregazioni

```
earthquakes.show(5)
```

```
+----------+-------+-------+
|      date|   city|richter|
+----------+-------+-------+
|1966-08-19|    mus|    4.7|
|1966-08-19|    mus|    4.7|
|1966-12-30|sakarya|    4.3|
|1967-05-22|  mugla|    4.6|
|1974-01-26| burdur|    4.0|
+----------+-------+-------+
only showing top 5 rows
```

Took: 0.893s, at 2019-03-05 03:37

```
earthquakes
  .groupBy("richter")
  .count()
  .orderBy(desc("count"))
  .show(5)
```

```
+-------+-----+
|richter|count|
+-------+-----+
|    4.6|  227|
|    4.9|  136|
|    4.3|  112|
|    4.2|  100|
|    4.1|   99|
+-------+-----+
only showing top 5 rows
```

Took: 1.618s, at 2019-03-05 03:38

Aggregazioni

La pietra angolare dell'analisi di big data

Spesso sono disponibili delle funzioni che restituiscono un risultato approssimato, molto piu' rapidamente delle corrispondenti funzioni esatte.

Tutte le aggregazioni sono disponibili come funzioni nel package

org.apache.spark.sql.functions

Count

df.count() : conta il numero di record. È un'azione!

df.select(count(«word»))

df.select(count(«*»))

df.select(countDistinct(«word»))

df.select(approx_count_distinct(«word», 0.1))

«Raggruppamenti» particolari

first(), last(), min(), max(), take()

Non generano dataframe: sono azioni che restituiscono oggetti Scala.

Statistiche

- Somma, sumDistinct
- Media, varianza,
- Deviazione standard
- Skewness, Kurtosis
- Covarianza

```
df2.select(covar_samp("richter","ms")).show()
```

```
+----------------------+
|covar_samp(richter, ms)|
+----------------------+
|     0.2956362571156822|
+----------------------+
```

Took: 1.148s, at 2019-03-01 22:57

```
ScatterChart(df2, fields=Some(("ms","richter")))
```

```
res32: notebook.front.widgets.charts.ScatterChart[org.apache.spark.sql.Dataset[org.apache.spark.sql.Row]] = <ScatterChart widget>
```

1000 or more entries total (Warning: showing only first 1000 rows)

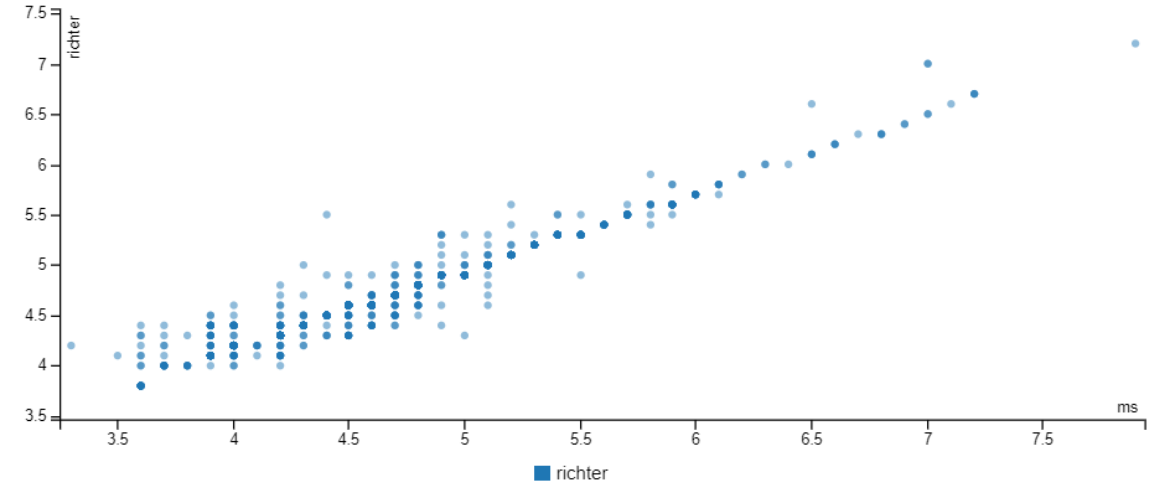

Took: 1.262s, at 2019-03-01 22:56

Un esempio con la somma

Suppongo di avere un dataframe con il numero di terremoti per città e per intensità

```
val df1 = earthquakes
  .filter("richter>4.5")
  .groupBy("richter", "city")
  .count()
  .orderBy($"city",desc("richter"))
df1.show(10)
```

```
+-------+--------+-----+
|richter|    city|count|
+-------+--------+-----+
|    5.7|   adana|    1|
|    5.4|   adana|    1|
|    4.9|   adana|    1|
|    4.8|   adana|    1|
|    4.6|   adana|    2|
|    5.7|adiyaman|    1|
|    5.0|adiyaman|    1|
|    4.9|adiyaman|    2|
|    4.7|adiyaman|    1|
|    4.6|adiyaman|    5|
+-------+--------+-----+
only showing top 10 rows
```

Un esempio con la somma

Voglio ottenere il conteggio totale per ogni città

```
df1
  .groupBy("city")
  .agg(sum("count").as("count"))
  .orderBy(desc("count"))
  .show(10)
```

```
+---------+-----+
|     city|count|
+---------+-----+
|  kutahya|   65|
|   burdur|   49|
|    mugla|   49|
|      van|   37|
|  denizli|   35|
|  erzurum|   32|
|  sakarya|   31|
|   manisa|   29|
|   bingol|   29|
|balikesir|   28|
+---------+-----+
only showing top 10 rows
```

Aggregazione su tipi complessi

In Spark le aggregazioni possono produrre tipi complessi, come ad es. liste di valori:

```
import scala.collection.mutable

val cities = df1
  .agg(collect_set("city"))
  .first()
  .getAs[mutable.WrappedArray[String]](0)
```

```
import scala.collection.mutable
cities: scala.collection.mutable.WrappedArray[String] = WrappedArray
(bitlis, amasya, bartin, isparta, hakkari, nevsehir, artvin, tunceli,
aksaray, bayburt, kocaeli, malatya, mus, van, erzurum, mugla, kirsehi
r, ankara, bilecik, mersin, edirne, bingol, kirikkale, denizli, aydi
n, giresun, mardin, elazig, sakarya, burdur, eskisehir, tekirdag, sii
rt, ardahan, karabuk, batman, istanbul, hatay, agri, bursa, duzce, ka
rs, usak, manisa, balikesir, cankiri, ordu, sanliurfa, sivas, adiyama
n, antalya, corum, gaziantep, afyonkarahisar, erzincan, tokat, yozga
t, diyarbakir, adana, izmir, osmaniye, kutahya, kirklareli, kastamon
u, konya, bolu, sirnak, canakkale, sinop, kayseri, samsun, trabzon, i
gdir, kahramanmaras)
```

Took: 10.529s, at 2019-03-05 04:05

Window Functions

Fin qui abbiamo visto due tipi di funzioni:

***substr()*, *to_date()*,** *ecc.*

Un valore per riga; input = riga

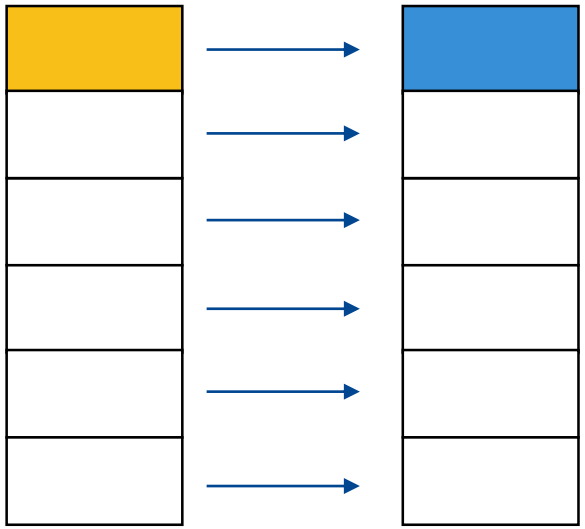

***count()*, *sum()*, *max()*,** *ecc.*

Un valore per gruppo; input = gruppo

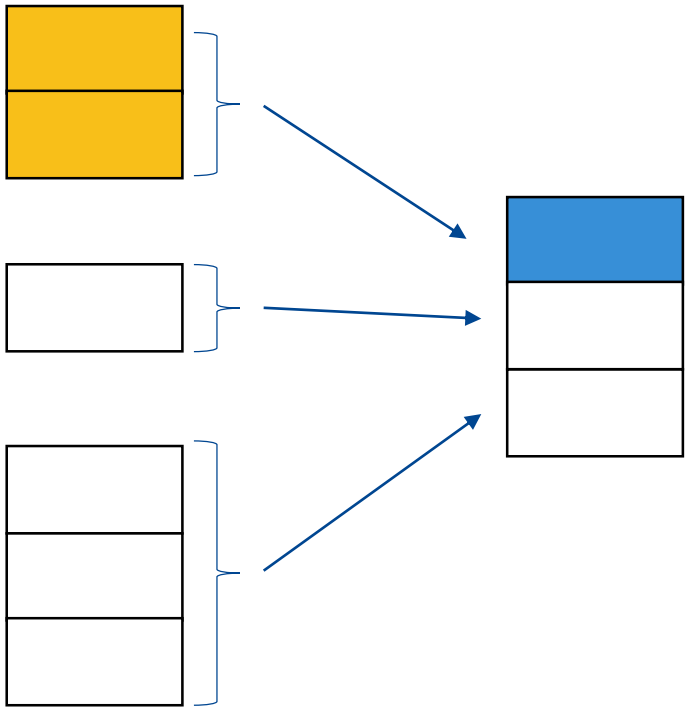

Window Functions

Una «***window function***» calcola un valore per ogni riga di un *DataFrame*, basandosi su un gruppo di righe chiamato «***frame***».

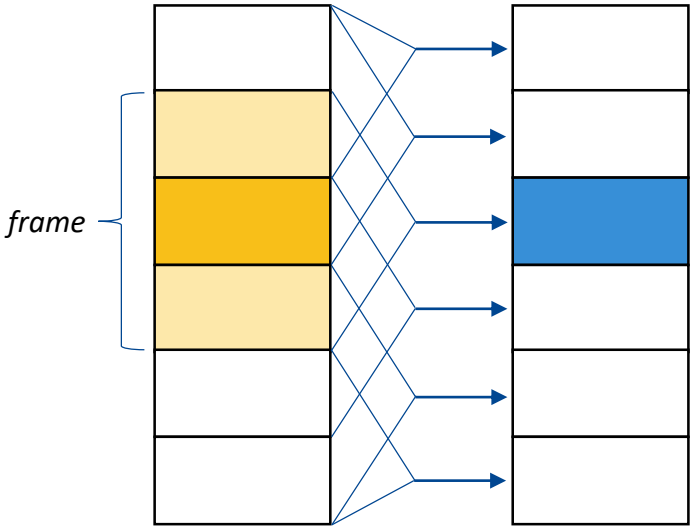

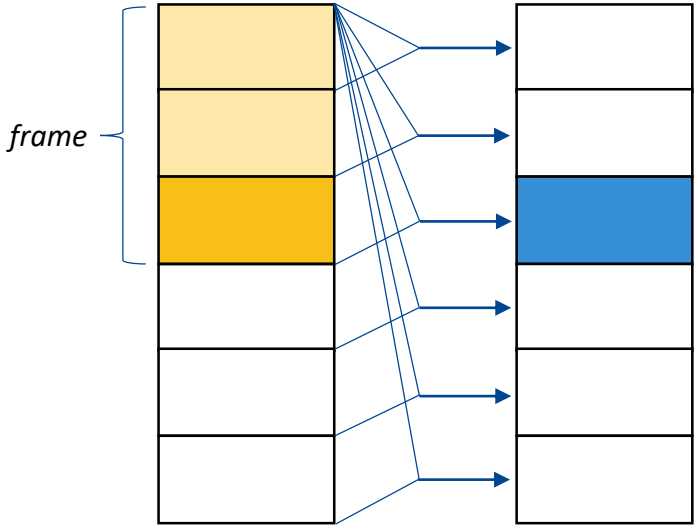

Window Functions

Le *Window Functions* possono essere usate per:

Calcolare una ***media mobile***

Calcolare una ***somma cumulativa***

Spark supporta tre tipi di *window function:*

- **Ranking** *(rank(), ntile(), rowNumber(), ecc.)*
- **Analitiche** (*cumeDist(), firstValue(), lag()*, ecc.)
- **Di aggregazione** (tutte le funzioni di aggregazione. Es. *sum()*, ecc.)

https://databricks.com/blog/2015/07/15/introducing-window-functions-in-spark-sql.html

Window Functions

In pratica:

```
import org.apache.spark.sql.expressions.Window

// definisco la finestra
val win = Window .partitionBy("city")
    .orderBy(desc("richter"))
    .rowsBetween(
        Window.unboundedPreceding,
        Window.currentRow)

// uso la window function
val rankedDf = df.select(
        $"city", $"date", $"richter",
        rank().over(win).as("rank"))
```

Window Functions

Ad esempio facciamo un filtro passabasso

```
LineChart(df4.orderBy("date"), fields=Some(("date","v")), groupField=Some("type"))
```

```
res64: notebook.front.widgets.charts.LineChart[org.apache.spark.sql.Dataset[org.apache.spark.sql.Row]] = <LineChart widget>
```

1000 or more entries total (Warning: showing only first 1000 rows)

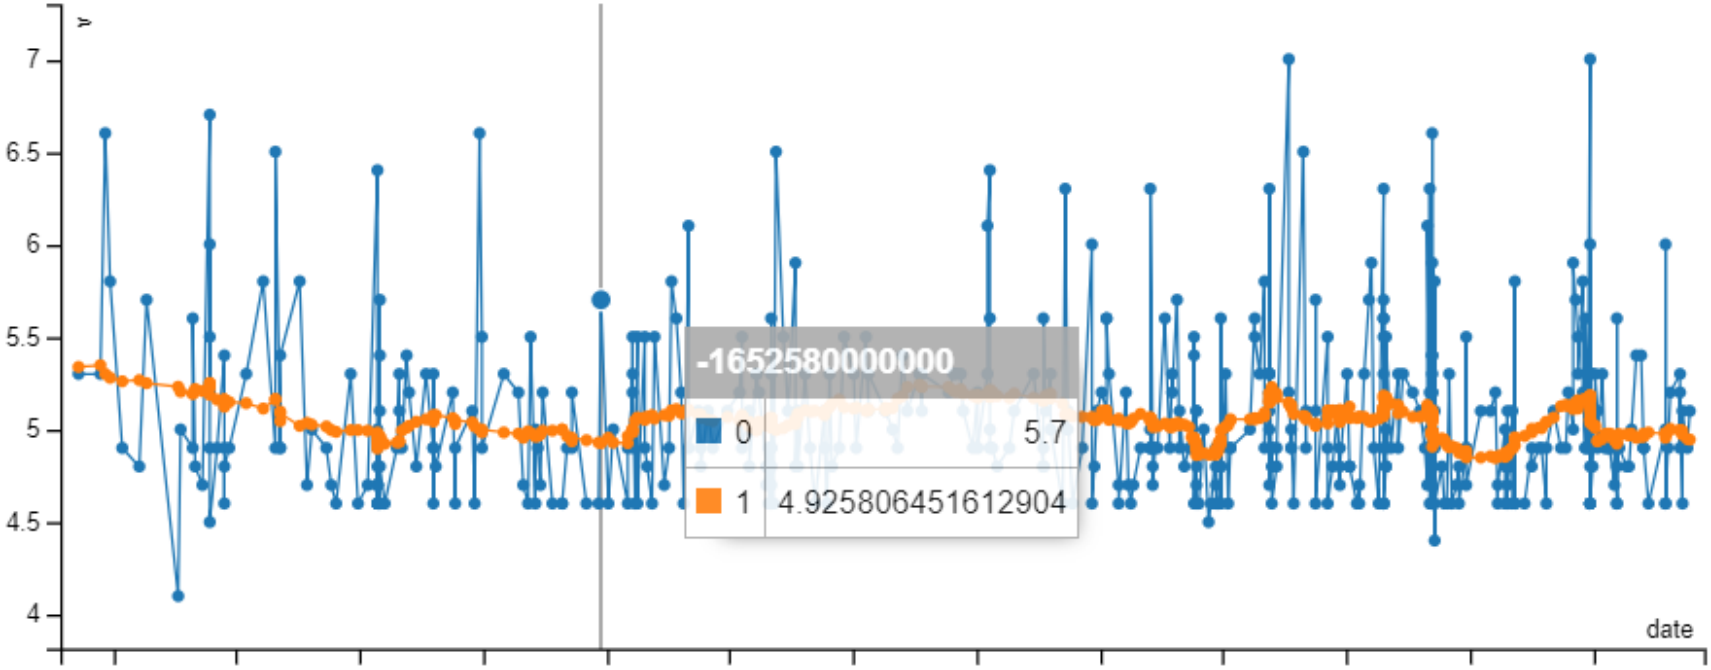

Window Functions

O elenchiamo i terremoti più forti per ogni città

```
import org.apache.spark.sql.expressions.Window
df.select($"city",$"date",$"richter",
          rank().over(Window
                           .partitionBy("city")
                           .orderBy(desc("richter"))
                           .rowsBetween(Window.unboundedPreceding, Window.currentRow))
          .as("rank"))
  .where("rank<=2")
  .orderBy("city", "rank")
  .show()
```

```
+--------------+----------+-------+----+
|          city|      date|richter|rank|
+--------------+----------+-------+----+
|         adana|1945-03-20|    5.7|   1|
|         adana|1952-10-22|    5.4|   2|
|      adiyaman|1964-06-14|    5.7|   1|
|      adiyaman|2008-09-03|    5.1|   2|
|afyonkarahisar|2002-02-03|    5.6|   1|
|afyonkarahisar|1924-11-20|    5.6|   1|
|          agri|1941-09-10|    5.6|   1|
|          agri|1936-05-01|    5.4|   2|
|       aksaray|1924-12-13|    4.9|   1|
|       aksaray|2011-06-13|    3.9|   2|
|        amasya|1962-04-01|    4.7|   1|
|        amasya|2003-09-27|    4.2|   2|
|        amasya|2013-03-07|    4.2|   2|
|        ankara|2007-12-20|    5.7|   1|
|        ankara|2007-12-26|    5.5|   2|
|       antalya|1969-01-14|    6.0|   1|
|       antalya|1911-04-30|    5.8|   2|
|       ardahan|1925-01-09|    5.7|   1|
|       ardahan|2011-01-19|    5.3|   2|
|        artvin|1934-11-02|    4.7|   1|
+--------------+----------+-------+----+
only showing top 20 rows

import org.apache.spark.sql.expressions.Window
```

Took: 2.383s, at 2019-03-02 11:37

Rollups

Aggregazione multidimensionale

Se ad es. vogliamo contare

- Quanti terremoti per città e intensità?
- Quanti terremoti per città?
- Quanti terremoti in tutto?

Possiamo farlo con un unico comando:

(ma attenzione ai null!)

```
df.na.drop().rollup($"city",$"richter").count.orderBy("city", "richter").show
```

```
+--------+-------+-----+
|    city|richter|count|
+--------+-------+-----+
|    null|   null| 1689|
|   adana|   null|   14|
|   adana|    3.3|    1|
|   adana|    3.5|    1|
|   adana|    3.9|    2|
|   adana|    4.1|    1|
|   adana|    4.3|    2|
|   adana|    4.5|    1|
|   adana|    4.6|    2|
|   adana|    4.8|    1|
|   adana|    4.9|    1|
|   adana|    5.4|    1|
|   adana|    5.7|    1|
|adiyaman|   null|   43|
|adiyaman|    3.4|    1|
|adiyaman|    3.5|    8|
|adiyaman|    3.6|    5|
|adiyaman|    3.7|    5|
|adiyaman|    3.8|    1|
|adiyaman|    3.9|    4|
+--------+-------+-----+
only showing top 20 rows
```

Took: 2.280s, at 2019-03-02 12:35

Cube

Aggregazione multidimensionale

Se ad es. vogliamo contare

- Quanti terremoti per città e intensità?
- Quanti terremoti per città?
- Quanti terremoti per intensità?
- Quanti terremoti in tutto?

Come l'esempio precedente, ma con ***cube()*** al posto di ***rollup()***

Pivot

I pivot permettono di trasformare righe in colonne e viceversa (da Spark 1.6)

Cos'è un PIVOT?

Raggruppa ***A***, fai «perno» su ***B*** e somma ***C***

A	B	C
G	X	1
G	Y	2
G	X	3
H	Y	4
H	Z	5

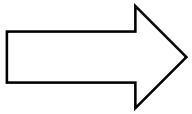

A	X	Y	Z
G	4	2	
H		4	5

```
df.groupBy("A").pivot("B").sum("C").show()
```

Funzioni di aggregazione definite dall'utente

UDAD (User-Defined Aggregation Functions)

Permettono di calcolare un valore a partire da un gruppo di record.

Bisogna creare una classe derivata da *UserDefinedAggregateFunction* e implementare:

- *inputSchema*
- *bufferSchema*
- *dataType*
- *deterministic*
- *initialize*
- *update*
- *merge*
- *evaluate*

Word count con i DataFrame

```scala
val text = spark.read.text("../data/divina_commedia.txt")
val cleanedText = text.withColumn("value", regexp_replace($"value", "[^a-zA-Z]"," "))
val words = cleanedText
  .select(explode(split($"value","\\s+")) as "word")
  .filter("word != ''")
  .withColumn("word", lower($"word"))
words
  .filter(length($"word")>8)
  .groupBy("word")
  .count()
  .orderBy(desc("count"))
```

```
text: org.apache.spark.sql.DataFrame = [value: string]
cleanedText: org.apache.spark.sql.DataFrame = [value: string]
words: org.apache.spark.sql.DataFrame = [word: string]
res9: org.apache.spark.sql.Dataset[org.apache.spark.sql.Row] = [word: string, count: bigint]
```

1 >>

Took: 6.169s, at 2019-03-05 09:19

word	count
"purgatorio"	35
"giustizia"	34
"principio"	26
"consiglio"	22
"maraviglia"	21
"cominciai"	20
"intelletto"	18
"qualunque"	17

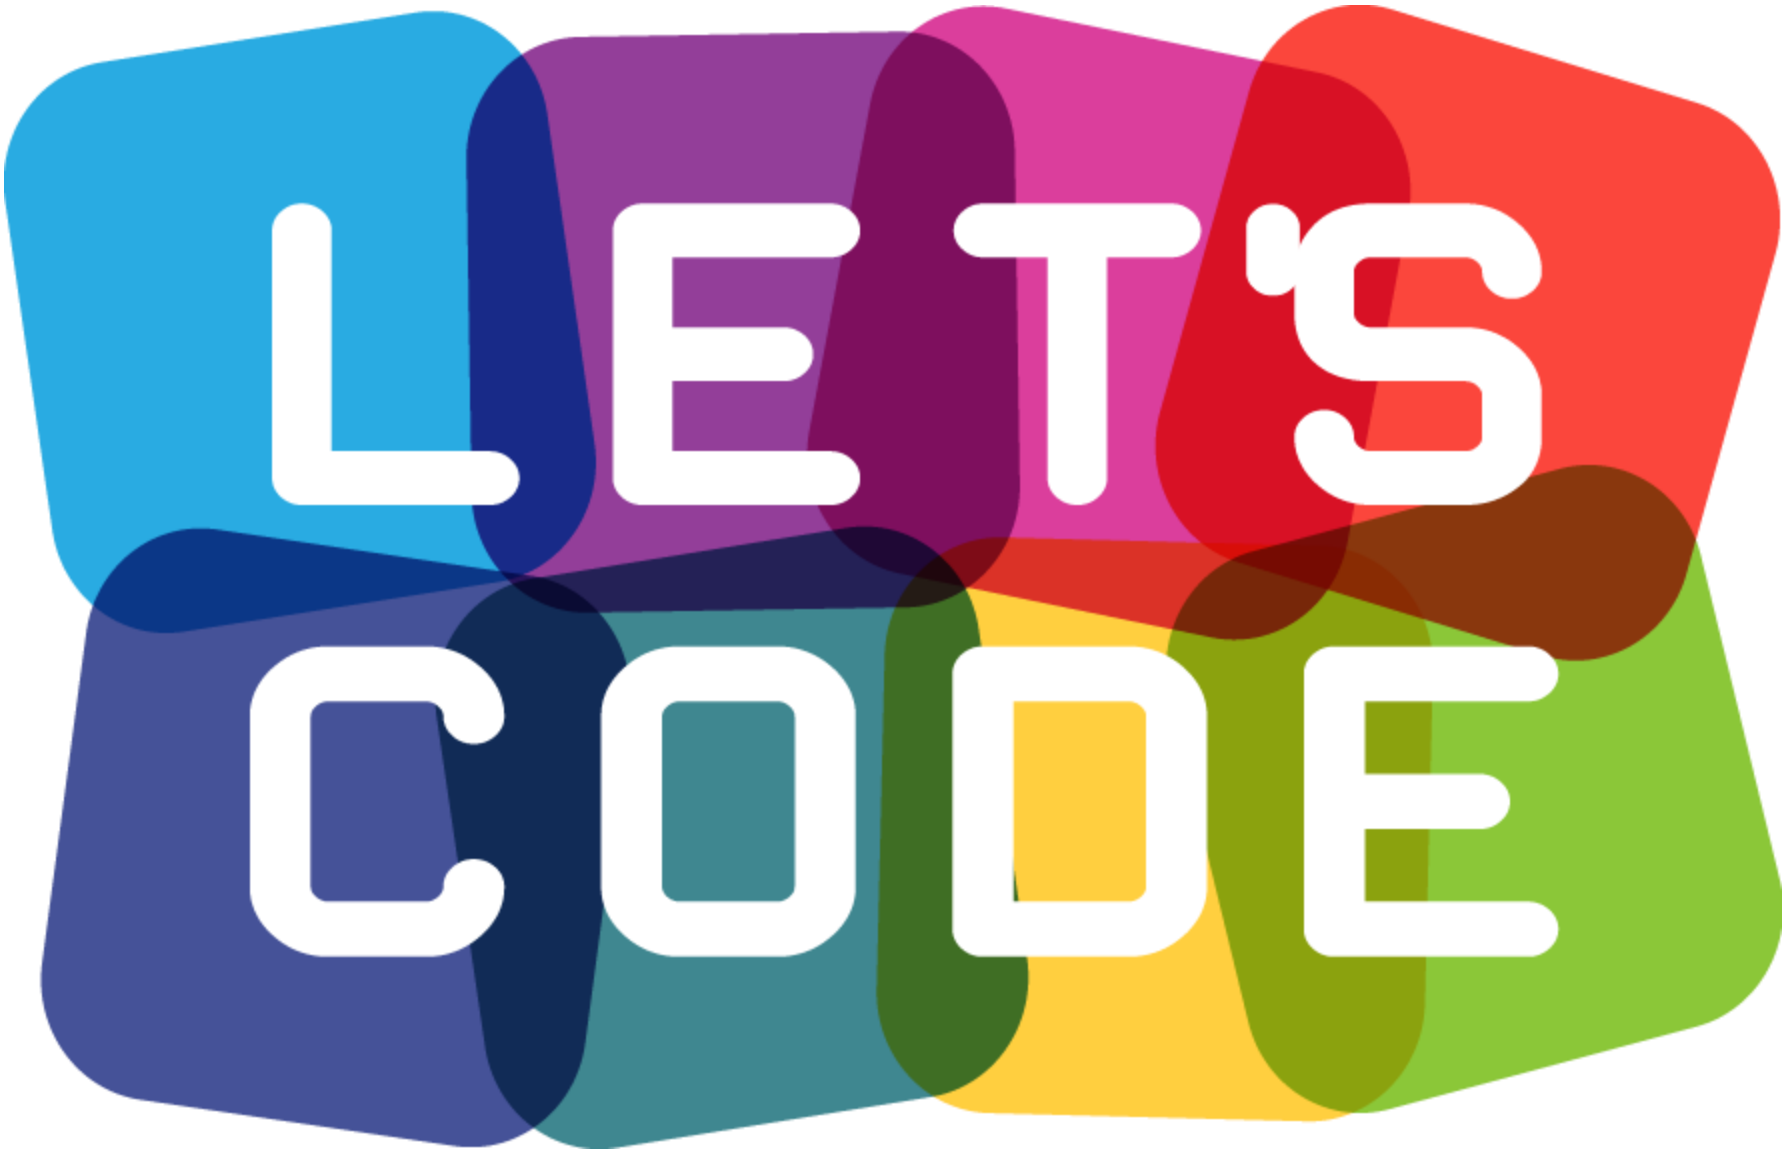
LET'S
CODE