

Quarto giorno: mattina

# Agenda 7/8

#### GraphFrames e altre librerie

#### **Packages**

Spark SQL, Spark Streaming, Spark ML, GraphFrames

#### **Spark Streaming**

Breve introduzione: ci sarà un corso dedicato

#### Spark ML

Breve introduzione: ci sarà un corso dedicato

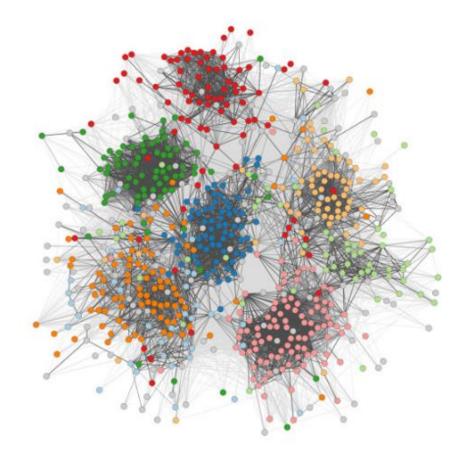
#### GraphFrames

Nota: GraphFrames (basato su DataFrames; 2016)

vs. GraphX (basato su RDD; 2014)

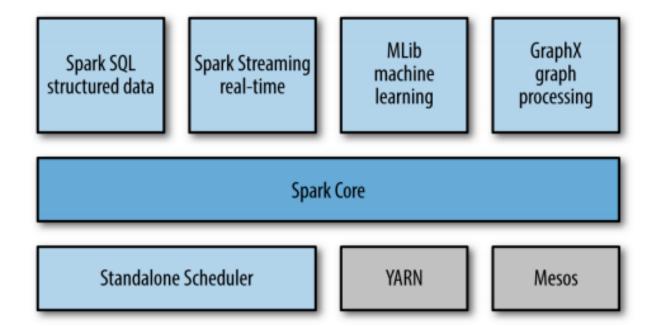
#### Esercizi di laboratorio

Esercizi di recapitolazione





- Spark SQL
- MLib: machine learning
- Spark Streaming (e il nuovo Structured Streaming)
- GraphX: analisi dei grafi.



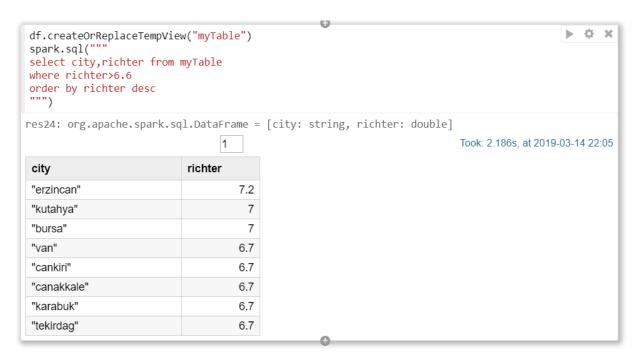


# Spark SQL

La libreria offre un'API strutturata di alto livello

Nei giorni scorsi abbiamo studiato l'astrazione basata sui *DataFrame* (definita in *org.apache.spark*)

La libreria permette di esprimere gli stessi costrutti con la sintassi SQL:





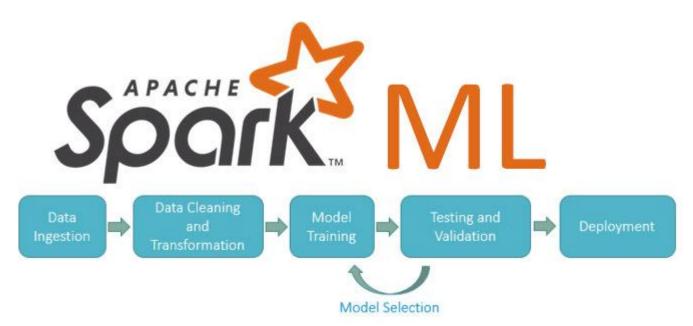
# **MLlib**

Libreria per il machine learning

In realtà ci sono due liberie:

- Spark ML (recente, basata sui DataFrame) e
- Spark MLlib (basata su RDD)

Verrà trattata in un corso dedicato.



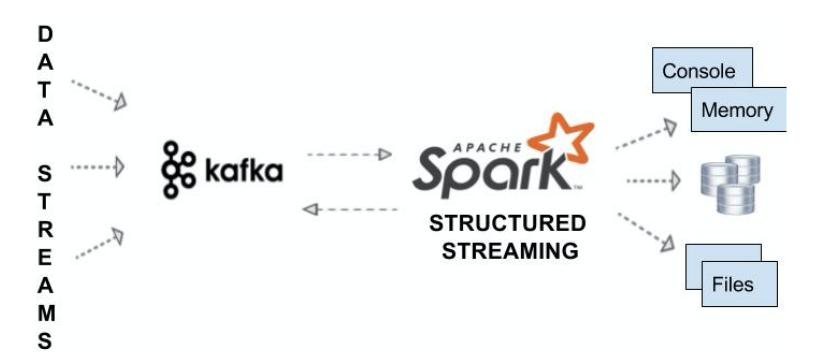


# Structured Streaming

Serve a gestire i flussi di dati in (quasi) real-time.

Anche in questo caso ci sono due librerie: Spark Streaming e Structured Streaming.

Verrà trattata in un corso dedicato.





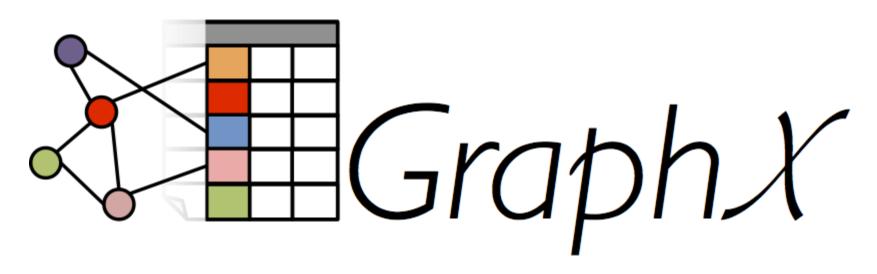
# **GraphX**

Analisi di grafi.

Anche in questo caso ci sono due librerie:

- GraphX basata su RDD; parte delle librerie standard
- GraphFrames basata su DataFrame; package separato

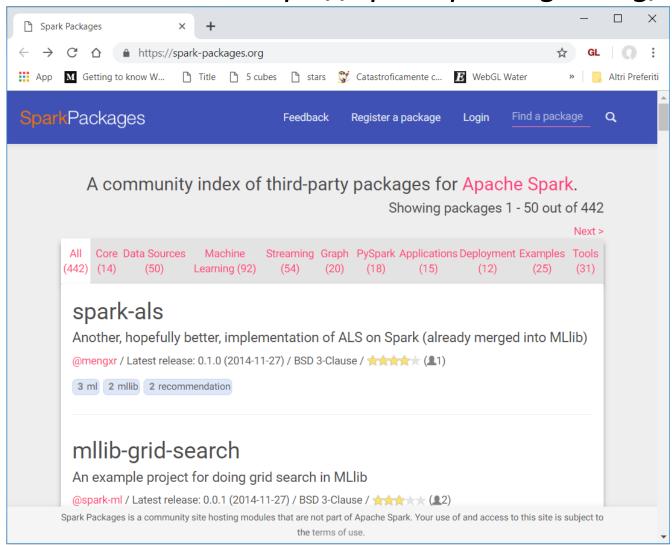
Questa mattina parliamo di *GraphFrames*!





## I Packages di Spark

# https://spark-packages.org/





## I Packages di Spark

### Fra gli altri:

- GraphFrames (miglioramento rispetto a GraphX)
- Diversi packages di machine learning e deep learning
- Connettori per vari datasources (Cassandra, Redshift, Avro, ecc.) e motori di ricerca (ElasticSearch, Google BigQuery, ecc.)
- E in genere più di 400 packages fra cui scegliere

### Per usare un package:

- Specificare la dipendenza nel file di build
- Fare download dei file JAR precompilati e includerli nel class path
- Includere il package a runtime aggiungendo un parametro ai comandi spark-shell o spark-submit



## Per usare GraphFrames

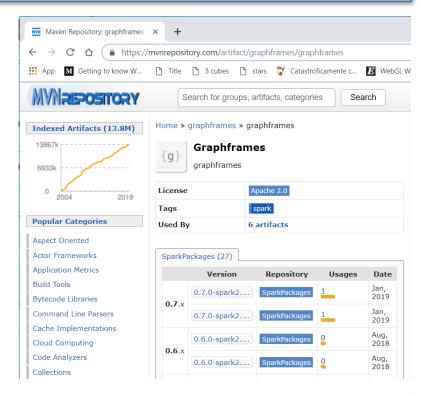
## Con spark-shell / spark-submit:

\$ spark-shell \
 --packages graphframes:graphframes:0.7.0-spark2.4-s\_2.11

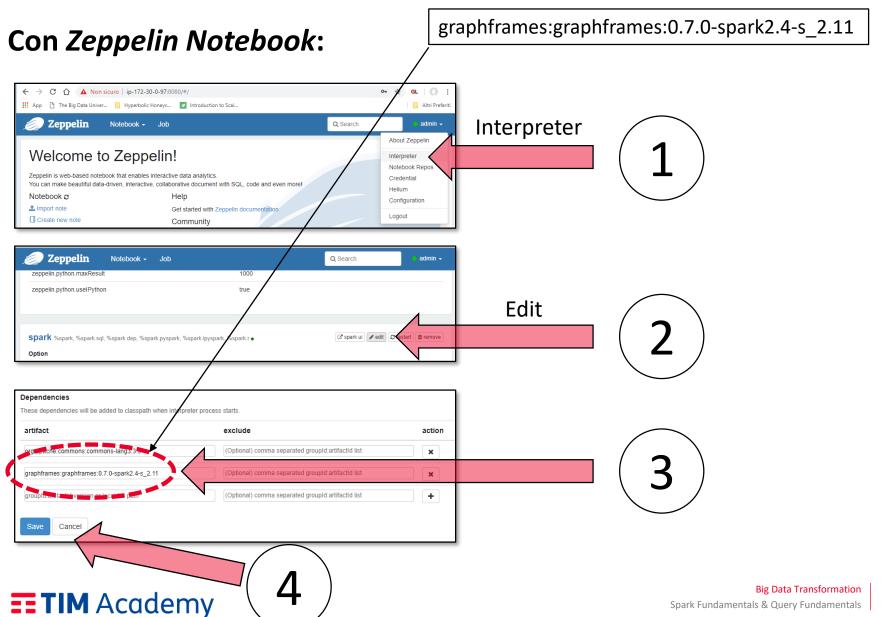
### Per trovare le versioni:

### **Maven Repository**

https://mvnrepository.com/artifact/graphframes/graphframes



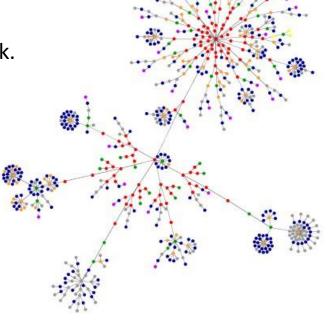
## Per usare GraphFrames



## GraphFrames

- Un *Grafo* è un insieme di *Nodi* (o *Vertici*) che possono essere collegati fra loro da linee chiamate *Archi*.
- Gli archi possono essere orientati (grafo diretto) oppure non orientati.
- È una struttura matematica che rappresenta relazioni fra entità. Ad esempio legami fra persone, società, ecc.

GraphFrames permette di analizzare grafi con Spark.





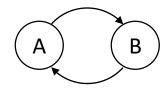
## Creare un grafo

```
import org.graphframes.GraphFrame
val graph = GraphFrame(vertices, edges).cache()
```

GraphFrames usa una convenzione per i nomi:

- Il DataFrame che contiene i vertici deve avere una colonna «id»
- Il DataFrame che contiene gli archi deve avere due colonne «src» e «dst»

La convenzione implica un grafo diretto. Per implementare un grafo non diretto bisogna definire due archi opposti per ogni coppia di nodi direttamente connessi





## Creare un grafo

## ,station\_data.csv

station_id	<u>name</u>	<u>lat</u>	long	dockcount	landmark	installation
2	San Jose Diridon Caltrain Station	37.329732	-121.901782	27	San Jose	8/6/2013
3	San Jose Civic Center	37.330698	-121.888979	15	San Jose	8/5/2013
4	Santa Clara at Almaden	37.333988	-121.894902	11	San Jose	8/6/2013

# trip\_data.csv

							<u> </u>			
<u>Trip ID</u>	<u>Duration</u>	Start Date	Start Station	<u>Start</u> <u>Terminal</u>	End Date	End Station	Erd Terminal	Bike #	Subscriber Type	<u>Zip</u> Code
913460	765	8/31/2015 23:26	Harry Bridges Plaza (Ferry Building)	50	8/31/2015 23:39	San Francisco Caltrain (Townsend at 4th)	70	288	Subscriber	2139
913459	1036	8/31/2015 23:11	San Antonio Shopping Center	31	8/31/2015 23:28	Mountain View City Hall	27	35	Subscriber	95032

```
import org.graphframes.GraphFrame

val vertices = spark.read.option("header",true).csv("../data/station_data.csv")
    .withColumnRenamed("station_id","id")
    .distinct()

val edges = spark.read.option("header",true).csv("../data/trip_data.csv")
    .withColumnRenamed("Start Station", "src")
    .withColumnRenamed("End Station", "dst")

val graph = GraphFrame(vertices, edges)

import org.graphframes.GraphFrame

Took: 1.368s, at 2019-03-15 00:29
```



## Query più semplici

```
graph.vertices.count()
graph.edges.count()
graph.inDegrees
graph.outDegrees
graph.degrees
```

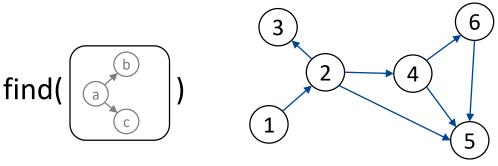
```
graph
.inDegrees
.orderBy(desc("inDegree"))
.show()
```

```
graph.edges
.groupBy("src", "dst").count()
.orderBy(desc("count"))
.show(10)
```

```
scala> graph.edges.
       groupBy("src", "dst").count().
      orderBy(desc("count")).
       show(10)
                                       dst|count|
|San Francisco Cal...|
                           Townsend at 7th
                                            3748
|Harry Bridges Pla...|Embarcadero at Sa...|
                                             3145
      2nd at Townsend|Harry Bridges Pla...|
                                            2973
      Townsend at 7th|San Francisco Cal...
                                            2734
|Harry Bridges Pla...|
                           2nd at Townsendl
                                            2640
 Embarcadero at Fo...|San Francisco Cal...
                                             2439
                                            2356
   Steuart at Market
                           2nd at Townsend
 Embarcadero at Sa...|
                         Steuart at Market
                                            2330
      Townsend at 7th|San Francisco Cal...|
                                            2192
 Temporary Transba...|San Francisco Cal...
only showing top 10 rows
```



## I motif: schemi strutturali nei grafi



```
val graph = GraphFrame(
   Seq(1,2,3,4,5,6).toDF("id"),
   Seq((1,2),(2,3),(2,4),(4,5),(4,6),(6,5),(2,5)).toDF("src","dst"))
val motifs = graph
   .find("(a)-[ab]->(b); (a)-[ac]->(c)")
   .where("b.id < c.id")</pre>
motifs
   .selectExpr("a.id as a","b.id as b","c.id as c")
   .show()
motifs: org.apache.spark.sql.Dataset[org.apache.spark.sql.Row] = [a: struct<id: int>, ab: struct<src: int,</pre>
dst: int> ... 3 more fields]
                                                                                      Took: 1.262s, at 2019-03-15 02:00
```

## Sotto-grafi

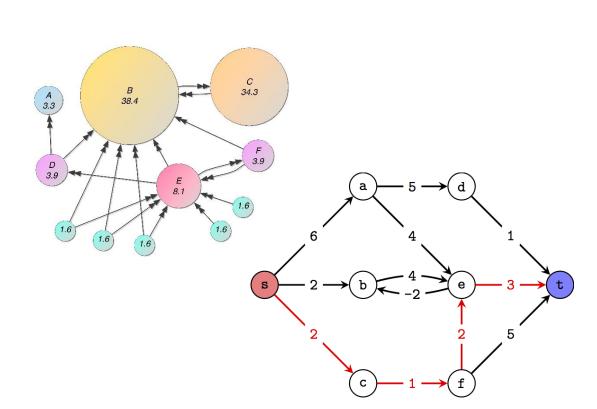
```
val g2 = g
  .filterEdges("relationship = 'friend'")
  .filterVertices("age > 30")
  .dropIsolatedVertices()
```

```
val paths = g.find("(a)-[e]->(b)")
  .filter("e.relationship = 'follow'")
  .filter("a.age < b.age")
val g3 = GraphFrame(
  g.vertices,
  paths.select("e.*"))</pre>
```

```
val g = GraphFrame(
     Seq(
           ("a", "Alice", 34),
           ("b", "Bob", 36),
           ("c", "Charlie", 30),
           ("d", "David", 29),
           ("e", "Esther", 32),
           ("f", "Fanny", 36),
           ("g", "Gabby", 60)
     ).toDF("id", "name", "age"),
     Seq(
           ("a", "b", "friend"),
           ("b", "c", "follow"),
           ("c", "b", "follow"),
            "f", "c", "follow"),
           ("e", "f", "follow"),
           ("e", "d", "friend"),
           ("d", "a", "friend"),
           ("a", "e", "friend")
     ).toDF("src", "dst", "relationship"))
```

## Algoritmi «standard» per i grafi

- Ricerca in ampiezza (breadth-first search, BFS)
- Ricerca componenti connesse
- Componenti fortemente connesse
- Label propagation
- PageRank
- Cammino minimo
- Conteggio dei triangoli





8

## Algoritmi «standard» per i grafi

La forma generale:

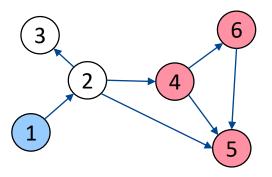
```
val result = graph.<algorithm>.<parameter>(...).run()
```

Spesso hanno bisogno di fare dei «checkpoint»

spark.sparkContext.setCheckpointDir("D:\\spark\\temp\\")



## BFS – Breadth-first search





## Label propagation

- Serve ad individuare le comunità
- Relativamente poco costoso, ma non garantisce risultati

